




데이터 수집과 웹개요

강사 : 배현진

본 문서는 지정된 수취인만을 위해 작성되었으며, 중요한 정보나 지식재산권을 포함하고 있을 수 있습니다. 본 문서에 포함된 정보의 전부 또는 일부를 무단으로 제3자에게 공개, 배포, 복사 또는 사용하는 것은 엄격히 금지됩니다.
This document may contain confidential information and/or copyright material. This document is intended for the use of the addressee only. Any unauthorized dissemination, distribution, copying or use the information contained in this document is strictly prohibited.

데이터 수집과 웹 구조

데이터 분석에는 “데이터”가 필요하다!
그렇다면 데이터는 어디에?

웹이란?

What is Web?

WWW World Wide Web

인터넷 상에 있는 하이퍼텍스트 구조를 활용해서
수많은 정보들을 연결해 주는 서비스



웹이란?

What is Hyper Text?

문서 내부에 또 다른 문서로 연결되는 참조를 집어 넣음으로써 웹 상에 존재하는 여러 문서끼리 서로 참조할 수 있는 기술

이때 문서 내부에서 또 다른 문서로 연결되는 참조를
하이퍼링크(hyperlink)



[Hyper Text]

웹의 기본 구조

Client와 Server란?



클릭한 페이지를 요청하는 PC

네트워크로 연결된 서버로부터 정보를 제공받는 컴퓨터




클릭된 페이지를 제공하는 PC

클라이언트에게 네트워크를 통해 서비스를 제공하는 컴퓨터

웹의 기본 구조 : Client와 Server와의 통신

Client 와 server 간의 통신은 클라이언트만 시작 가능

웹 서버는 많은 정보와 서비스를 제공하지만 클라이언트의 요청이 있는 경우에만 제공



웹의 기본 구조 : HTTP

HTTP (Hyper Text Transfer Protocol)


웹 브라우저와 웹 서버 간에 데이터를 주고받을 때 사용되는 프로토콜 / 웹 페이지를 로드하는 데 사용

http://

Protocol?

정의 : 컴퓨터 네트워크에서 데이터 전송을 위해 통신에 사용되는 규칙

예시 : FTP / IMAP / POP3 / DNS



웹의 기본 구조 : HTTP

HTTP request message 예시

Request line (요청 라인) **GET /somedir/page.html HTTP/1.1**

Header line (헤더라인)
Host: www.someschool.edu
User-agent: Mozilla/4.0
Connection: close
Accept-language: fr

사용자 명령 코드 클라이언트가 요청하는 특정 리소스의 경로

HTTP response message 예시

Status Code (상태코드) **HTTP/1.1 200 OK** 메시지를 생성한 시간

Header line (헤더라인)
Date: Sun, 28 Aug 2017 08:56:53 GMT
Server: Apache/2.4.27 (Linux)
Last-Modified: Fri, 20 Jan 2017 07:16:26 GMT
ETag: "10000000565a5-2c-3e94b66c2e680"
Accept-Ranges: bytes
Content-Length: 44
Connection: close
Content-Type: text/html
X-Pad: avoid browser bug

데이터 **<html><body><h1>It works!</h1></body></html>**

웹의 기본 구조 : HTTP

HTTP Request message의 주요 사용자 명령 코드 종류

GET

서버로부터 개체 다운로드

POST

클라이언트가 서버로 데이터 전송

PUT

클라이언트가 서버에 데이터 업로드

DELETE

서버에 저장된 데이터 삭제

웹의 기본 구조 : HTTP

HTTP Response message의 상태코드

Status Code	Meaning	
100-199	정보 응답(Information)	현재 http 메시지의 진행 상태
200-299	성공 응답(Success)	http 메시지의 진행 상태에 따른 성공 상태
300-399	리다이렉션 응답(Redirection)	클라이언트는 다른 서버나 리소스를 통해 다시 요청 메시지를 보내야함
400-499	클라이언트 에러 (Client Error)	클라이언트의 http 메시지에 서버가 성공적으로 작동하지 못하게 하는 오류가 있음
500-599	서버 에러 (Server Error)	서버가 클라이언트의 응답에 실패함

웹의 기본 구조 : URL

URL
(Uniform Resource Locator)

웹 문서의 수많은 서비스를 제공하는 서버들에 있는
파일의 위치를 표시하는 표준

http://www.wikibook.co.kr/webtext/index.html
프로토콜 정보 자원을 가진 컴퓨터의 위치 자원이 있는 폴더 자원 이름

= 인터넷 주소

Request 메시지를 요청하고 응답받아보자!

Request 라이브러리

접근할 웹 페이지의 데이터를 요청/응답받기 위한 라이브러리

실행코드

```
In [1]:  1 import requests
```

설치코드

```
1 !pip install requests_toolbelt
```

Request Lib



[Requests라이브러리를 활용하여 Melon사이트의 데이터 요청해보기]

멜론 사이트 Url : <https://www.melon.com/>

① Requests라이브러리를 통해 데이터 요청 (**get함수활용**)

② 상태(response)코드 출력하기

▶ Q 상태코드가 무엇을 나타낼까?

(통신 성공시 코드 [200]이 출력된다)

Request Lib

상태 코드 4XX

클라이언트 에러

- 브라우저가 아닌 것(Python)에 대한 접속 차단
요청할 때, header에 User-Agent를 지정하고 접근하면 해결 가능!
- 클라이언트는 웹브라우저 = 헤더를 임의로 설정해주면 접근이 가능하다
- 헤더는 딕셔너리 형식으로 사용된다.
- get 에 헤더 지정

```
In [2]: 1 # <Response [406]> = 요청은 했지만 통신에 실패했습니다!  
2 req.get("https://www.melon.com/")  
Out [2]: <Response [406]>
```


실행코드

요청을 보낸 사용자 환경 (Mozilla 정보/버전 + 운영체제 정보 + 렌더링 엔진 정보 + 브라우저)

```
head = {'User-Agent' : 'Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36  
(KHTML, like Gecko) Chrome/96.0.4664.110 Safari/537.36'}
```

```
1 res = req.get("https://www.melon.com/", headers = head)
```

User Agent 정의



정리!

1. 웹은 클라이언트와 서버와의 **http 메시지** 전달을 통해 **서비스를 요청, 제공**받는 구조를 가지고 있다.
2. HTTP 메시지는 **request** 메시지와 **response** 메시지로 이루어져 있다.
2. 서버는 request 메시지를 받지 못하면 서비스를 제공할 수 없다.
3. 웹사이트의 정보를 가져올 때 웹브라우저에서의 요청이 아닌 경우 요청이 거절당하는 경우가 있으므로, **헤더를 지정하여 해결**한다.