





웹크롤링 개요

강사 : 배현진

본 문서는 지정된 수취인만을 위해 작성되었으며, 중요한 정보나 지식재산권을 포함하고 있을 수 있습니다. 본 문서에 포함된 정보의 전부 또는 일부를 무단으로 제3자에게 공개, 배포, 복사 또는 사용하는 것은 엄격히 금지됩니다.
This document may contain confidential information and/or copyright material. This document is intended for the use of the addressee only. Any unauthorized dissemination, distribution, copying or use the information contained in this document is strictly prohibited.

데이터 수집과 웹 구조


Web crawler



Web 거미줄



Crawl 기어가다



Web crawler


- 자동화된 방법으로 웹에서 다양한 정보를 수집하는 소프트웨어
- 스스로 기어다니면서 웹 페이지를 탐색

내가 가지고 오게되는 데이터는 무엇일까?

빅데이터의 의미 / 빅데이터가 뭐야



디지털 환경에서 생성되는 수치, 문자, 이미지,
영상 데이터를 모두 포함하는 대규모 데이터



데이터 수집과 웹 구조


정형



관계형 데이터베이스(RDB)
스프레드시트, CSV

ID	Name	AGE	SEX
01	KIM	32	M
02	LEE	26	F
03	PARK	72	F
04	CHOI	15	M


반정형



비정형



SNS



웹 크롤링과 웹 스크래핑의 차이



Crawling

VS



Scraping

BeautifulSoup 라이브러리

웹 스크래핑

- BeautifulSoup 라이브러리
- tag / class 탐색하기

스크래핑 대표 라이브러리

스크래핑 시에 사용하는 라이브러리?

BeautifulSoup 라이브러리!



BeautifulSoup

Requests로 받은 데이터를
BeautifulSoup객체화를 진행해주는
오픈소스 라이브러리

스크래핑 대표 라이브러리

BeautifulSoup 라이브러리

Request로 가져온 데이터 -> 분석할 수 있게 객체화

▶ get 함수로 먼저 raw 데이터 가져오기

▶ import BeautifulsUp

```
soup = BeautifulSoup(html, 'html.parser')
```

인스턴스 해당 문자열 `###.parser`
 parser의 종류 지정

raw 데이터 `html.parser`
 lxml

설치코드

```
1 !pip install bs4
```

실행코드 1

```
1 from bs4 import BeautifulSoup as bs
```

BeautifulSoup 라이브러리 : select method

BeautifulSoup 라이브러리_select 메소드

CSS selector를 통해 tag 객체를 찾아 반환
html.parser / lxml를 통해 객체화 선행 후 진행
출력결과는 리스트 형태로 반환된다.

```
1 soup = bs(res.text, "html.parser")
```

```
1 soup = bs(res.text, "lxml")
```

◆ 태그 찾기

▶ html 태그 입력

```
1 soup.select("tag_name")
```

◆ 특정 태그와 class

▶ 온점을 통해 태그와 class 이름을 분리

▶ 클래스 내 공백 발생시 온점으로 구분

```
1 soup.select('tag_name.class_name')
```

◆ 특정태그의 하위태그

▶ > 를 통해 하위태그 명시

```
1 soup.select('tag > child_tag')
```

```
1 soup.select('tag.class_name > child_tag')
```

BeautifulSoup 라이브러리 예제 _멜론 사이트 메뉴 가져오기

MelOn 지민x로꼬, Smeraldo Garden Marching Band 급상승 10. 서지오 8

멜론차트 최신음악 장르음악 멜론DJ 멜론TV 스타포스트 매거진 뮤직어워드 어학 뮤직웨이브 *beta* 마이뮤직

최신 앨범 > 전체 | 국내 | 해외 1/9 < >



토스터즈



BORAN (보란)



멜트



이정석



SCARY'P



Austin (오스틴)



New Album
KATSEYE
강렬한 보컬과 퍼포먼스로 완성된 서머송!

멜론을 더 안전하게 이용하세요. 회원가입

로그인



2024 Wheen In Concert
07.20 - 21 | 올림픽홀 멜론티켓
예매하기

인기 있어요 지금 이슈가 되는 아티스트의 인기 콘텐츠입니다. 1/2 < >







멜론 차트 > 2024.06.30 13:00 기준

TOP100	POP	☆ 아티스트
1 - 0		Small girl (feat.... 이영지

BeautifulSoup 라이브러리 실습 예제 1



네이버 코스피 [종목명, 현재가]

https://finance.naver.com/sise/sise_quant.naver

네이버에 네이버 코스피검색 - 코스피200 : 네이버페이 증권- 왼쪽 배너 거래 상위

	코스피	코스닥									
	종목명	현재가	전일비	등락률	거래량	거래대금	매수호가	매도호가	시가총액	PER	ROE
1	KODEX 200선물 인버스2X	2,150	▼ 10	-0.46%	114,594,926	244,359	2,145	2,150	23,613	N/A	N/A
2	KEC	3,955	▲ 245	+6.60%	30,800,103	119,815	3,960	3,965	5,724	-31.39	-24.43
3	써니전자	4,855	▲ 195	+4.18%	23,311,188	116,381	4,900	4,905	1,692	33.95	9.92
4	KODEX 인버스	3,990	▼ 15	-0.37%	19,665,163	78,306	3,995	4,000	11,411	N/A	N/A
5	KODEX 코스닥 150선물인버스	4,030	▲ 15	+0.37%	18,488,069	74,623	4,020	4,025	4,215	N/A	N/A
6	KODEX 레버리지	24,015	▲ 145	+0.61%	14,560,038	350,954	23,960	23,965	16,474	N/A	N/A
7	삼성전자	78,600	▲ 300	+0.38%	12,578,542	993,379	78,600	78,700	4,692,249	15.24	9.99
8	한신기계	3,870	▲ 230	+6.32%	12,448,506	50,022	3,875	3,880	1,256	39.49	4.24
9	조일알미늄	2,170	▲ 190	+9.60%	10,233,470	22,239	2,190	2,195	2,661	30.56	-7.85
10	이엔플러스	4,875	▲ 85	+1.77%	9,367,685	45,810	4,910	4,915	2,503	-16.70	-27.80
11	제이준코스메틱	1,120	▲ 90	+8.74%	8,886,687	9,944	1,115	1,120	834	-2.92	-37.83
12	신원	2,775	▼ 145	-4.97%	8,537,747	23,858	2,750	2,755	2,652	71.15	-3.92
13	NPC	10,650	▲ 150	+1.43%	8,507,633	92,216	10,650	10,700	3,911	18.08	6.53
14	쌍방울	808	▼ 2	-0.25%	8,278,650	6,737	808	809	2,122	35.13	-8.46
15	한화투자증권	6,720	▲ 330	+5.16%	7,516,313	49,988	6,720	6,730	14,418	11.29	5.58



수집된 데이터의
개수 체크

BeautifulSoup 라이브러리 실습 예제 2



벅스차트 [순위, 곡, 아티스트] 수집

Bugs!

눈을 감으면 우주가 보여

말라스원의 이종성할 280화

벅스 VIP 멤버십 안내

이웃권 구매 | 상품권 등록

벅스차트 | 대한민국 | 전체 장르

곡 앨범 유적PD 앨범 영상 커넥트 곡 커넥트 영상

실시간 일간 주간 2022.06.30 23:00

☐ ☒ 순위 ☐ + 재생목록에 추가 ☒ 내 앨범에 담기 ☒ 다운로드 ☐ 전체 듣기(재생목록 추가) ☐ 전체 듣기(재생목록 교체)

순위	곡	아티스트
1	없었던 일로	헤이즈 (Heize)
2	BOOM	이민혁 (HUTA)
3	Red Wine	이민혁 (HUTA)
4	위험해	이민혁 (HUTA)
5	기다리고 있어	이민혁 (HUTA)
6	Real Game (Like Messi)	이민혁 (HUTA)
7	Stay This Way	프로미스나인
8	LOVE DIVE	IVE (아이브)
9	POP!	나영 (TWICE)

<https://music.bugs.co.kr/chart>

✓ 개발자도구를 활용해보기
(selector 사용)

✓ 수집한 데이터를
데이터프레임으로 테이블화

✓ 데이터 프레임의 인덱스를
랭킹으로 대체

BeautifulSoup 라이브러리 실습 예제 3

URL의 규칙 발견하기

여러페이지에서 원하는 정보를 수집하기 위해서는
해당 페이지들의 **URL이 특정한 규칙**을 가지고 있는지 살펴보자

<https://music.bugs.co.kr/musicpost?page=1>

<https://music.bugs.co.kr/musicpost?page=2>

<https://music.bugs.co.kr/musicpost?page=3>

<https://music.bugs.co.kr/musicpost?page=4>

<https://music.bugs.co.kr/musicpost?page=5>

BeautifulSoup 라이브러리 실습 예제 3



박스 뮤직 포스트 [제목, 마크, 날짜] 수집

BeautifulSoup 라이브러리 실습 예제 3의 스크린샷입니다. 화면은 'music.bugs.co.kr/musicpost' 페이지를 보여줍니다. 페이지 상단에는 'Bugs!' 로고와 검색창, 로그인/회원가입 버튼이 있습니다. 좌측에는 '박스 VIP 멤버십 안내'와 '이웃권 구매', '상품권 등록' 버튼이 있습니다. 메인 콘텐츠는 '뮤직포스트' 섹션으로, '전체', '뮤직&', '주간 핫이슈', '완결된 시리즈' 탭이 있습니다. 현재 '뮤직&' 탭이 선택되어 있습니다. 메인 콘텐츠에는 6개의 카드가 표시되어 있습니다. 첫 번째 카드에는 '주간 핫이슈' 태그와 '프림로즈 - Single Album [REVIVAL] 스웨덴 현지 발매 기념 인터뷰'라는 제목과 '2024.06.17' 날짜가 표시되어 있으며, 'EVENT' 태그가 붙어 있습니다. 두 번째 카드에는 'Favorite' 태그와 'Favorite - COMING SOON! (6/19)'라는 제목과 '2024.06.14' 날짜가 표시되어 있으며, 'HOT' 태그가 붙어 있습니다. 세 번째 카드에는 '뮤직&' 태그와 '팜송으로 배우는 영어! 83. Billie Eilish - 'LU NCH''라는 제목과 '2024.06.12' 날짜가 표시되어 있습니다. 네 번째 카드에는 '주간 핫이슈' 태그와 '이승철 - 돌아온 보컬의 신, 신곡 '비가 와' 발매 기념 인터뷰'라는 제목과 '2024.06.11' 날짜가 표시되어 있으며, 'EVENT' 태그가 붙어 있습니다. 다섯 번째 카드에는 '주간 핫이슈' 태그와 'Paul Blanco - essential: With Artist 두 번째 곡 'Every Night' 라이브클립 촬영 비하인드'라는 제목과 '2024.06.10' 날짜가 표시되어 있으며, 'EVENT' 태그가 붙어 있습니다. 여섯 번째 카드에는 '주간 핫이슈' 태그와 'nochexintoma - 썬의 트렌디함을 이끄는 노 체션토마의 새 앨범 [i i i] 발매 기념 인터뷰'라는 제목과 '2024.06.03' 날짜가 표시되어 있으며, 'EVENT' 태그가 붙어 있습니다.

<https://music.bugs.co.kr/musicpost>

✓ 개발자도구를 활용해보기
(selector 사용)

✓ 수집한 데이터를
데이터프레임으로 테이블화

✓ 데이터 프레임의 인덱스를
랭킹으로 대체