




페이지 번호 규칙찾기

강사 : 배현진

본 문서는 지정된 수취인만을 위해 작성되었으며, 중요한 정보나 지식재산권을 포함하고 있을 수 있습니다. 본 문서에 포함된 정보의 전부 또는 일부를 무단으로 제3자에게 공개, 배포, 복사 또는 사용하는 것은 엄격히 금지됩니다.
This document may contain confidential information and/or copyright material. This document is intended for the use of the addressee only. Any unauthorized dissemination, distribution, copying or use the information contained in this document is strictly prohibited.

[1] 페이지 번호의 규칙 찾기

URL의 규칙 발견하기

여러페이지에서 원하는 정보를 수집하기해서는
해당 페이지들의 **URL이 특정한 규칙**을 가지고 있는지 살펴보자

<https://music.bugs.co.kr/musicpost?page=1>

<https://music.bugs.co.kr/musicpost?page=2>

<https://music.bugs.co.kr/musicpost?page=3>

<https://music.bugs.co.kr/musicpost?page=4>

<https://music.bugs.co.kr/musicpost?page=5>

[1] 페이지 번호 규칙찾기 : 예제1



박스 뮤직 포스트 [제목, 마크, 날짜] 수집

<https://music.bugs.co.kr/musicpost>

The screenshot shows the Bugs! Music Post page. The left sidebar contains navigation links: Bugs! VIP 멤버십 안내, 이용권 구매, 상품권 등록, 박스차트, 최신 음악, 뮤직4U, 장르, 뮤직포스트, 테마, 뮤직PD 앨범, 추천앨범 라이브, 연도별, 투표, Favorite, 하트 충전소, 커넥트, 라디오, 박스TV, 스페셜 라이브, 내 음악, 최근 들은 곡, 가장 많이 들은 곡. The main content area is titled '뮤직포스트' and has tabs for '전체', '뮤직&', '주간 핫이슈', and '완결된 시리즈'. The '뮤직&' tab is selected. The first post in the grid is highlighted with a red box. It features a photo of four women and the text: '주간 핫이슈', '프림로즈 - Single Album [REVIVAL] 스웨덴 현지 발매 기념 인터뷰', and '2024.06.17'. The post is marked as an 'EVENT'.

제목	날짜	마크
프림로즈 - Single Album [REVIVAL] 스웨덴 현지 발매 기념 인터뷰	2024.06.17	EVENT
Favorite - COMING SOON! (6/19)	2024.06.14	HOT
팜송으로 배우는 영어! 83. Billie Eilish - 'LU NCH'	2024.06.12	
이승철 - 돌아온 보컬의 신, 신곡 '비가 와' 발매 기념 인터뷰	2024.06.11	EVENT
Paul Blanco - essential: With Artist 두 번째 곡 'Every Night' 라이브클립 촬영 비하인드	2024.06.10	EVENT
nochexintoma - 썬의 트렌디함을 이끄는 노 체션토마의 새 앨범 [i i i] 발매 기념 인터뷰	2024.06.03	

✓ 수집한 데이터를
데이터프레임으로 테이블화

Selenium & BeautifulSoup

현재 웹페이지 소스 가져오기 : `driver.page_source`

html row 데이터를 request로 가져오는 것이 아닌
현재 열려있는 driver의 html 소스를 가지고 올 수 있다.

왜?

request를 쓰지않죠?

```
1 res = req.get("https://www.melon.com/", headers = request_headers)
```

```
1 soup = bs(res.text, 'lxml')
```

VS

```
1 soup = bs(driver.page_source, "lxml")
```



request로 html을 가져오면 처음에 입력한

URL에 대한 소스만 가져올 수 있다

동적 크롤링을 통해 다른 페이지로


이동하게 되면 페이지 소스가 업데이트 되지않음

[2] 페이지 번호 규칙 찾기

크롤링을 하다보면 page를 넘겨가면서
데이터를 수집해야할 일이 생긴다.

그런데 각 page 수 마다 URL이 달라지지 않는다면..?


Xpath 혹은 css selector의 규칙성을 살펴보고
formatting 하여 수집한다.



[2] 페이지 번호 규칙찾기 : 예제2



카카오 맵 [장소, 별점 수집]



```
soup =  
bs(driver.page_source,"html.parser")
```

✓ kakaomap에 키워드 넣어 검색하기

✓ 장소 이름 / 별점 수집

✓ BeautifulSoup과 Selenium 같이 사용해보기