

LG 전자 DX School 6 기
CX 학업성취도_평가지

- 시험일시 : 2026. 6. 25(목) 10:30 ~ 12:30
- 시험 시간 : 2 시간
- 출제 및 감수 : 1~6 기 강사진
- 과목 및 유형

머신 러닝	이론 20 문제 80 점, 실습 2 문제 20 점	100 점
-------	-----------------------------	-------

* 시험 규칙

1. 오픈 북으로 실시 : 교재 포함 기존 수업 자료 참고 가능
2. 구글링/GPT 는 불가
3. 일부 문제는 부분 점수가 있어요
4. 답안지는 jupyter notebook 으로 작성해주세요
5. 답안지 파일명 : 답안_CX_6 기_O 반_이름.ipynb
6. 답안지는 각자의 구글 클래스룸으로 제출해주세요.

머신 러닝

◆ 1~20 번 : 이론 문제 (총 80 점)

1 번	머신러닝 기반 데이터 분석 수행 시 일반적인 절차 를 순서에 맞게 나열하세요. ㉠ 데이터 준비 혹은 수집 ㉡ 데이터에 대한 모델훈련 ㉢ 데이터 전처리와 탐색 ㉣ 모델 성능 평가 ㉤ 비즈니스 이해 및 문제 정의	3 점
2 번	다음 문장이 설명하는 학습방법은 무엇인가요? 설명변수(혹은 독립변수, 특성(Feature) 등으로 표현)와 목적변수(혹은 출력값, 반응변수, 종속변수, 목표변수 등으로 표현) 간의 관계성을 표현해내거나 미래 관측을 예측해 내는 것에 초점이 있으며 주로 인식, 분류, 진단, 예측 등의 문제 해결에 적합하다.	3 점
3 번	다음 중 머신러닝의 정의로 가장 적절한 것은? (1) 명시적으로 프로그래밍된 규칙만 수행하는 시스템 (2) 데이터를 통해 패턴을 학습하는 시스템 (3) 데이터베이스를 관리하는 기술 (4) 알고리즘을 수동으로 설계하는 과정	4 점
4 번	다음 중 지도학습에 해당하지 않는 것은? (1) Logistic Regression (2) K-means (3) Decision Tree (4) KNN	4 점
5 번	머신러닝 모델을 학습하기 전, 데이터 전처리 방법 3 가지를 쓰세요.	4 점
6 번	K-means/PCA 적용 전 데이터 스케일링이 필요한 이유를 쓰세요.	4 점

7 번	PCA 를 사용할 때 얻을 수 있는 장점 을 2 가지 쓰세요.	4 점
8 번	비지도 학습에 대한 설명으로 옳은 것을 모두 고르시오. (1) K-means 군집화는 군집의 개수 K 를 사전에 정해야 한다. (2) K-means 군집화는 초기 중심값 설정에 따라 서로 다른 군집화 결과가 나올 수 있다. (3) PCA 는 데이터의 분산이 큰 방향을 기준으로 새로운 축을 찾아 차원을 축소하는 기법이다. (4) PCA 는 원래 변수들의 의미를 그대로 유지하면서 차원을 축소하므로, 변환된 축도 기존 변수와 동일한 해석이 가능하다.	4 점


◆ 9~10 번은 아래 범주형 데이터셋을 참고하세요.

poisonous	cap- shape	cap- surface	cap- color	bruises	odor	gill- attachment
p	x	s	n	t	p	f
e	x	s	y	t	a	f
e	b	s	w	t	l	f

9 번	범주형 데이터 를 머신러닝 모델에 적용하기 위해서 전처리 하는 방법 중 데이터를 0, 1 로만 변형하는 방법은 무엇인가요?	4 점
10 번	위에서 작성한 답에 대한 설명으로 맞는 것을 모두 고르세요. (1) 각 컬럼의 클래스 수에 맞게 새로운 컬럼을 생성하고 해당 클래스의 위치에는 1 을, 다른 클래스의 위치에는 0 을 부여한다 (2) 특성을 증가시켜줌으로써 과대적합을 줄여준다. (3) 클래스의 수가 많다면 컬럼이 너무 많아져서 메모리 측면에서 비효율적이 될 수 있다. (4) 데이터들이 순서가 있고, 우선순위의 의미를 가질 때 사용하는 것이 효과적이다.	4 점

11 번	일반적으로 훈련 데이터와 테스트 데이터를 나눌 때 비율 은 얼마 정도가 적당한가요?	4 점
12 번	데이터셋을 훈련/테스트 세트로 분할하지 않고, 데이터셋 모두를 이용해 훈련하고, 데이터셋 모두를 이용해 테스트할 경우에 발생할 수 있는 올바른 문제점을 고르시오. (1) 모델이 데이터셋 모두를 알고 있기 때문에 과소 적합이 발생할 수 있다. (2) 훈련 데이터와 테스트 데이터 분리하지 않아서 일반화 모델인지 평가하기 어렵다. (3) 데이터 편향이 발생하기 쉽다. (4) 전체 데이터를 사용하기 때문에 분산이 커질 가능성이 높아 모델의 성능을 떨어뜨린다.	4 점
13 번	다음 중 과적합을 줄이는 방법으로 적절하지 않은 것은? (1) Dropout (2) Regularization (3) 데이터 증가 (4) 모델 복잡도 증가	4 점
14 번	Train / Validation / Test 데이터셋을 나누는 이유를 설명하고 각 데이터셋들의 의미를 작성하시오. 이유 : Train : Validation : Test :	4 점


◆ 15~16 번 문제는 아래 그래프를 참고하세요. 다항식의 차수가 증가함에 따라 평균 제곱근 오차(RMSE)의 변화를 나타낸 그래프입니다. (RMSE 는 MSE 값에 제곱근을 붙인 것, RMSE 는 낮을수록 좋은 결과임.)



15 번	테스트 RMSE 가 가장 낮아지는 모델 복잡도는? (1) 1 (2) 2 (3) 3 (4) 7	4 점
16 번	Flexibility(다항식의 차수)가 4 이상인 경우부터는 Training 데이터의 오차율은 감소하지만, Test 데이터의 오차율은 증가하고 있다. 이러한 현상 을 무엇이라 하나요?	4 점

17 번	agging 과 oosting 의 차이는 무엇인가요?	4 점
18 번	텍스트 마이닝에 대한 설명 중 옳은 설명을 모두 고르시오. (1) 비정형텍스트 데이터에서 의미 있는 정보를 추출하는 기술이다. (2) 텍스트 데이터는 별다른 전처리 없이 바로 학습이 가능하다. (3) 토큰화란 글자 타입의 데이터를 의미 있는 숫자로 변경하는 작업이다. (4) 일정한 단위로 글자를 분리하는 행위를 형태소 분석이라고 한다. (5) 텍스트마이닝은 빈도분석, 감성분석, 연관어분석, 토픽모델링 등이 있다.	4 점
19 번	TF-IDF, 코사인 유사도, LDA 의 특징을 쓰세요. (1) TF-IDF : (2) 코사인 유사도 : (3) LDA :	6 점
20 번	다음 중 분류 문제에서 주로 사용하는 손실 함수는? (1) MSE (2) Cross Entropy (3) MAE (4) RMSE	4 점

◆ 21~22 번, 실습 문제 (총 20 점)

21 번	아래 그림은 100 명의 암환자에 대해 예측한 한 모델의 Confusion_matrix 이다. 모델의 정확도(Accuracy), 재현율(Recall), 정밀도(Precision)를 계산하세요. (1) 정확도 : (2) 재현율 : (3) 정밀도 : 	6 점
22 번	sklearn 패키지를 이용하여 아래와 같이 주석에 맞게 교차검증 진행하고 실행결과와 같이 출력하는 코드를 작성시오. <pre>import pandas as pd from sklearn.model_selection import cross_val_score from sklearn.linear_model import LogisticRegression import numpy as np # (1) bmi_500.csv data 불러오기 # (2) bmi data 를 문제와 답으로 분리 # (3) LogisticRegression 분류 모델 생성 # (4) 5-fold 교차검증 수행 # (5) 교차검증 결과와 평균 정확도 출력</pre>	14 점

수고 많으셨습니다!