

BERT(Bidirectional Encoder Representations from Transformers)

BERT의 특징

전이학습 모델

사전 학습 모델

BERT 구조

BERT의 Pre-training과 Fine-Tuning

BERT 학습 방식 (Pre-Training)

입력 데이터

Task 1 : Masked Language Mode (MLM)

Task 2 :Next sentence Prediction (NSP)

Fine-Tuning

다른 사전 학습 모델(OpenAI GPT, ELMo)과 구조 비교

결과

참고자료

BERT의 특징

전이학습 모델


- 구글의 Devlin(2018)이 제안한 BERT는 사전 학습된 대용량의 레이블링 되지 않는 (unlabeled) 데이터를 이용하여 언어 모델(Language Model)을 학습하고 이를 토대로 특정 작업(문서 분류, 질의응답, 번역 등)을 위한 신경망을 추가하는 전이 학습 방법

사전 학습 모델

- 대용량의 데이터를 직접 학습시키기 위해서는 매우 많은 자원과 시간이 필요하지만 BERT 모델은 기본적으로 대량의 단어 임베딩 등에 대해 사전 학습이 되어 있는 모델을 제공하기 때문에 상대적으로 적은 자원만으로도 충분히 자연어 처리의 여러 일을 수행할 수 있음
- 이전에는 단어 임베딩을 위해 Word2Vec, Glove, Fasttext 방식을 사용했지만, BERT가 자연어 처리 분야의 11개 실험에서 가장 좋은 성능을 차지하면서 많이 사용되고 있음

BERT 구조


- BERT라는 모델은 하나이지만 전이학습을 하기 때문에 아래 두 단계로 구성함
 - 대량의 문장으로 먼저 학습하는 Pre-training 단계
 - 사용자가 원하는 task에 맞게 모델을 학습하는 Fine-Tuning 단계



BERT의 Pre-training과 Fine-Tuning

BERT 학습 방식 (Pre-Training)


BERT는 아래 두 가지 목적을 가지고 학습을 수행하면서 토큰들의 임베딩 정보와 모델의 파라미터를 학습



- BERT는 두개의 문장으로 구성된 시퀀스 데이터를 입력받는다. 여기서 입력되는 문장의 토큰들 중 일부는 마스킹 처리됨
- CLS 토큰은 입력되는 시퀀스 데이터의 시작을 알려주는 역할을 하며, 시퀀스 전체의 정보를 반영
- SEP 토큰은 두 개의 시퀀스가 입력되었을 때, 문장을 구분하기 위해서 사용
- BERT 모델은 여러 개의 인코더 블록으로 구성되고 최종적으로 각 토큰에 대한 hidden state인 T_i 를 출
- 출력층의 C는 입력된 문서의 전체 특성을 담고있는 임베딩 벡터
- 감성분석이나 텍스트 분류 같은 경우에는 C 토큰의 정보만을 사용하기도 한다.
- 최종 출력된 결과를 보면 NSP와 MLM을 동시에 실시한 것을 알 수 있음

입력 데이터

- BERT의 input representation은 그림과 같이 세 가지 임베딩 값의 합으로 구성
- BERT는 세가지 임베딩을 합치고 이에 Layer정규화와 Dropout을 적용하여 입력으로 사용
- BERT는 이미 총3.3억 단어(BookCorpus + Wikipedia Data)의 거대한 코퍼스를 정제하고, 임베딩하여 학습시킨 모델로 이를 스스로 라벨을 만들고 준지도학습을 수행



Token Embeddings

- Token Embeddings는 Word piece 임베딩 방식을 사용(총 30,000개의 단어 임베딩 사용)
- Word Piece 임베딩은 자주 등장하면서 가장 긴 길이의 sub-word을 하나의 단위로 만듦

- 즉, 자주 등장하는 단어(sub-word)는 그 자체가 단위가 되고, 자주 등장하지 않는 단어(rare word)는 더 작은 sub-word로 쪼개어짐
- 이는 이전에 자주 등장하지 않은 단어를 전부 Out-of-vocabulary(OOV)로 처리하여 모델링의 성능을 저하했던 문제를 해결할 수 있음
- 입력받은 모든 문장의 시작으로 [CLS] 토큰(special classification token)이 주어지며 이 [CLS] 토큰은 모델의 전체 계층을 다 거친 후 토큰 시퀀스의 결합된 의미를 가짐
- 여기에 간단한 classifier을 붙이면 단일 문장, 또는 연속된 문장을 분류할 수 있고 만약 분류 작업이 아니라면 이 토큰을 무시
- 또한 문장의 구분을 위해 문장의 끝에 [SEP] 토큰을 사용함

Segment Embeddings


- 시퀀스가 2개가 입력될 때, 각 시퀀스를 구분하는 정보
- 토큰으로 나누어진 단어들을 다시 하나의 문장으로 만들고 첫 번째 [SEP] 토큰까지는 0으로 그 이후 [SEP] 토큰까지는 1 값으로 마스크를 만들어 각 문장들을 구분함

Position Embeddings

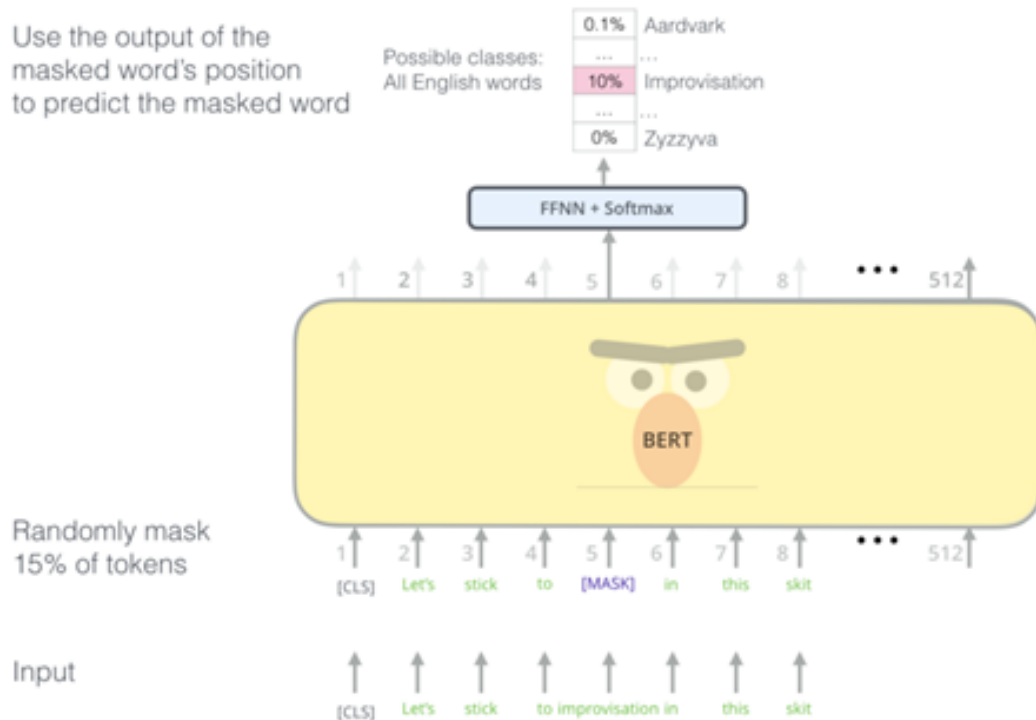
- Position Embeddings는 토큰의 순서를 인코딩
- 트랜스포머에서 사용된 positional embedding 과 동일함

Task 1 : Masked Language Mode (MLM)

- MLM은 전체 시퀀스에서 15%를 랜덤하게 MASK 토큰으로 변경




- $w_1 \sim w_5$ 가 입력될 때, w_4 가 MASK 토큰으로 변경되어 입력됨
- 여기서 $w_1 \sim w_5$ 는 인코딩 블록을 거쳐서 $O_1 \sim O_5$ 로 출력되고, 다시 뉴럴넷 레이어를 거쳐서 최종적으로 $w'_1 \sim w'_5$ 로 출력됨
- w'_4 가 w_4 와 동일한 방향으로 나타나도록 학습하는 것이 MLM임



Task 2 :Next sentence Prediction (NSP)

- Question Answering이나 Natural Language Inference와 같은 작업은 두 개의 문장 간의 관계를 이해할 수 있어야 수행 가능함
- GPT나 엘모와 같은 언어모델은 문장 단위로 학습하기 때문에 문장 간의 관계를 학습하기가 어려움
- 이러한 문제를 해결하기 위해서 BERT는 Binarized next sentence prediction 방식을 사용했고 이 과정은 MLM과 함께 수행됨



- 두 문장이 주어졌을 때, 두 문장의 순서를 예측하는 방식
 - 순서가 맞으면 `IsNext`, 틀리면 `NotNext`

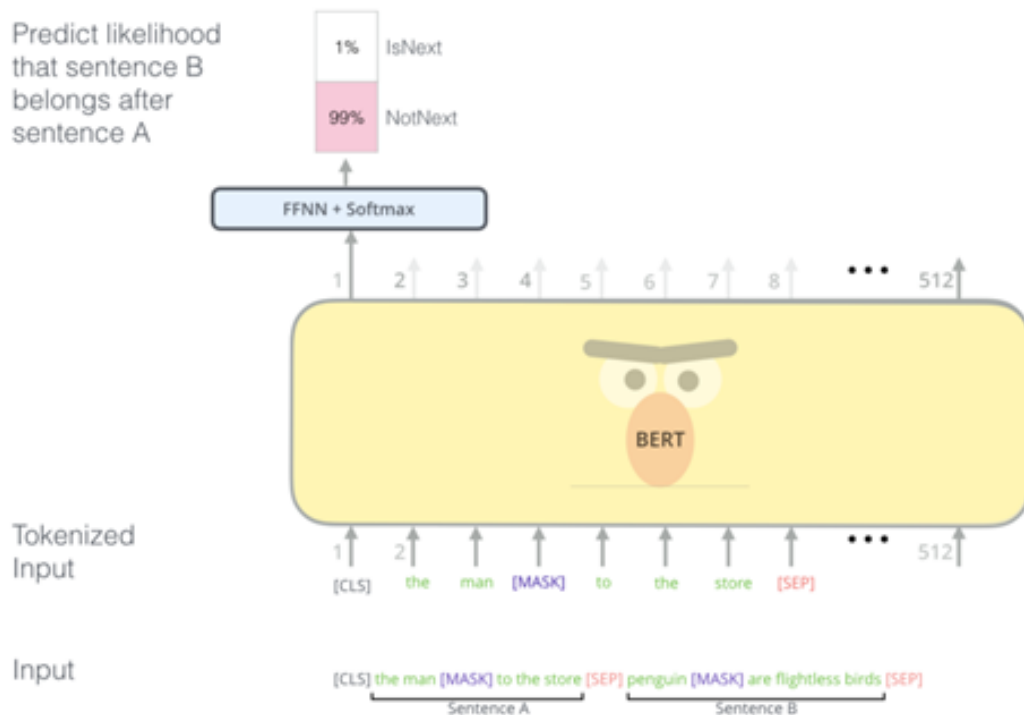
Input = [CLS] the man went to [MASK] store [SEP]
 he bought a gallon [MASK] milk [SEP]

Label = `IsNext`

Input = [CLS] the man [MASK] to the store [SEP]
 penguin [MASK] are flight ##less birds [SEP]


Label = `NotNext`

- 두 문장 간 관련이 고려되어야 하는 NLI와 QA의 파인 튜닝을 위해 두 문장의 연관을 맞추는 학습을 진행함




Fine-Tuning


- BERT는 전이학습을 이용하므로 pre-training 이후, Fine-tuning 학습을 진행
- pre-training과 다르게 fine-tuning은 self-attention의 도입으로 인해 매우 간단함
- 원하는 task에 맞춰서 입력과 출력을 정한 다음, pre-training이 완료된 모델을 이용하여 downstream task를 수행
- 간단하게 말하면 원하는 task(QA, NLI, Text classification 등등)에 맞춰서 모델 학습을 진행하면 됩니다. 특히 BERT의 output 중 하나인 C(CLS)는 입력 전체에 대한 정보를 담고 있고 또한 일정한 dimension size가 나오기 때문에 추론이나 감정 분석 등의 classification에 사용하면 좋음




(a) Sentence Pair Classification Tasks:
MNLI, QQP, QNLI, STS-B, MRPC,
RTE, SWAG



(b) Single Sentence Classification Tasks:
SST-2, CoLA




(c) Question Answering Tasks:
SQuAD v1.1



(d) Single Sentence Tagging Tasks:
CoNLL-2003 NER

다른 사전 학습 모델(OpenAI GPT, ELMo)과 구조 비교



- BERT는 ELMO나 GPT 등의 기존 모델과는 다르게 양방향 트랜스포머(bidirectional Transformer)를 사용한 것이 특징
- 저자들은 양방향 트랜스포머 구조가 문장을 이해하는데 더 효과적이라고 주장함
- 기존 GPT 모델은 단방향(왼쪽-> 오른쪽)으로 입력이 들어가며, ELMO는 방향이 다른 두 개의 단방향 구조를 이용하여 합친 구조라는 부분에서 BERT와이 차이가 존재
- 이에 비해 BERT는 사전 학습을 위해 두 가지 방법 (Masked Language Model(MLM)과 Next Sentence Prediction(NSP))를 사용하는데 이 방법들은 BERT가 양방향으로 학습되어 문맥을 더 잘 파악할 수 있게 함

결과

System	Dev F1	Test F1
ELMo (Peters et al., 2018a)	95.7	92.2
CVT (Clark et al., 2018)	-	92.6
CSE (Akbik et al., 2018)	-	93.1
Fine-tuning approach		
BERT _{LARGE}	96.6	92.8
BERT _{BASE}	96.4	92.4
Feature-based approach (BERT _{BASE})		
Embeddings	91.0	-
Second-to-Last Hidden	95.6	-
Last Hidden	94.9	-
Weighted Sum Last Four Hidden	95.9	-
Concat Last Four Hidden	96.1	-
Weighted Sum All 12 Layers	95.5	-

- 발표 당시에는 엄청난 센세이션을 불러왔던 모델. 현재는 더욱 개선된 모델들이 많이 연구되고 발표되었지만, 그 시초가 되는 모델로 의미가 있음
- 현재 현업에서도 전이학습으로 가장 많이 사용되는 모델
- BERT는 일반 NLP모델에서 잘 작동하지만, Bio, Science, Finance 등 특정 분야의 언어모델에 사용하려면 잘 적용되지 않는다고 함
- 이는 사용 단어들이 다르고 언어의 특성이 다르기 때문에 특정 분야에 대해 BERT를 적용하려면 특정 분야의 특성을 수집할 수 있는 언어데이터들을 수집하고, 언어모델 학습을 추가적으로 진행해주어야 합니다.

참고자료

- <https://storage.googleapis.com/bert-wsd-vis/demo/index.html?#word=dog>
- 구글 BERT 문장 유사도 시각화
- <https://www.youtube.com/watch?v=lwtexRHoWGO>