

LSTM(Long Short Term Memory)

정의

구조

1) o : Output Gate

2) f : Forget Gate

3) g : 기억 셀에 추가하는 새로운 기억

4) i : Input Gate


순전파

역전파

요약

정의

- LSTM은 RNN의 기울기 소실 문제를 방지하는 신경망
- RNN의 Hidden Layer에 기억 셀, Input/Output/Forget Gate를 추가한 형태




[그림 1] RNN과 LSTM의 차이

- RNN의 Hidden Layer에는 Hidden State인 H_{t-1} 과 Input인 X_t , 가중치인 W_t 로 구성되어 있음
 - 이들은 Hidden Layer 안에서 선형결합과 하이퍼볼릭 탄젠트 함수를 거친 후 H_t 를 내보냄
- LSTM의 Hidden Layer에는 기억 셀인 C_{t-1} 과 Input/Output/Forget Gate가 있음

- 기억 셀은 데이터를 LSTM 계층 내에서만 주고받음. 즉, LSTM 계층 내에서만 이동하고 다른 계층으로 출력하지는 않음.
- 기억 셀 C_t 에는 시각 t 에서의 LSTM의 기억이 저장돼 있음. 이것은 과거로부터 시각 t 까지에 필요한 모든 정보가 저장돼 있다고 가정하며 이 기억을 바탕으로 다음 시각의 LSTM에 Hidden State H_t 를 출력함

구조



[그림 2] LSTM 구조

1) o : Output Gate

- Output Gate는 다음 Hidden State H_t 의 출력을 담당하는 게이트
- Output Gate에서 Hidden State H_{t-1} 과 Input X_t 를 연산한 것을 $\tanh(C_t)$ 에 곱함
- 이를 통해 $\tanh(C_t)$ 에서 얼마만큼의 양을 H_t 로 출력시킬지 결정
- 가중치와 X_t , H_{t-1} 간의 선형결합에 시그모이드 함수를 씌운 형태 [식 1]
- Output Gate 결과에 $\tanh(C_t)$ 를 곱해 Hidden State H_t 로 생성하는 과정 [식 2]

$$o = \sigma(x_t w_x^{(o)} + h_{t-1} w_h^{(o)} + b^{(o)})$$

[식 1] Output Gate

$$h_t = o \odot \tanh(c_t)$$

[식 2] Hidden State Ht 구하는 방식

2) f : Forget Gate

- Forget Gate는 이전 단계에서의 기억 셀 Ct-1에서 불필요한 기억을 잊게 해주는 게이트
- Forget Gate에서 Ht-1과 Xt를 연산한 것을 Ct-1에 곱함
- 이를 통해 Ct-1에서 얼마만큼의 양을 지워서 Ct로 연산할지 결정함 [식 3]
- Forget Gate 결과에 Ct-1를 곱해 기억 셀 Ct로 생성하는 과정 [식 4]

$$f = \sigma(x_t w_x^{(f)} + h_{t-1} w_h^{(f)} + b^{(f)})$$

[식 3] Forget Gate

$$c_t = f \odot c_{t-1} + g \odot i$$

[식 4] 기억 셀 Ct를 구하는 방식

3) g : 기억 셀에 추가하는 새로운 기억

- 새로 기억해야 할 정보를 기억셀에 추가하기 위해 [그림 2]에서와 같이 tanh 노드를 추가함
- [그림 2]에서 tanh노드와 이전 단계의 기억 셀 Ct-1을 더하면서 기억 셀에 새로운 '정보'가 추가됨
- g가 Ct-1에 더해짐으로써 새로운 기억이 생깁니다 [식 5]

$$g = \tanh(x_t w_x^{(g)} + h_{t-1} w_h^{(g)} + b^{(g)})$$

[식 5] 기억 셀에 추가하는 새로운 기억 g 계산

4) i : Input Gate

- Input Gate는 g의 각 원소가 새로 추가되는 기억으로써의 가치가 얼마나 큰지를 판단함

- 새 기억 g를 모두 수용하지 않고, 적절히 부분적으로 선택하는 것이 이 게이트의 목표임 [식 6]

$$i = \sigma(x_t w_x^{(i)} + h_{t-1} w_h^{(i)} + b^{(i)})$$


[식 6] Input Gate

- 앞에서 구한 i, g, f를 이용해서 이전 단계에서의 기억 셀 C_{t-1} 을 C_t 로 변환하는 과정 [식 7]

$$c_t = f \odot c_{t-1} + g \odot i$$


[식 7] 기억 셀 C_t 를 구하는 방식

순전파




[그림 3] LSTM 순전파

- 여기서 주목해야 할 점은 H_t 입니다. 이 행렬을 행 기준으로 4등분해 i, f, o, g 각각에 해당하는 활성화함수를 적용하는 방식으로 i, f, o, g 를 계산



[그림 3] LSTM 순전파에서의 H_t

역전파



[그림 4] LSTM 순전파에서의 역전파

요약

- LSTM은 순환신경망(RNN)의 한 종류로, 긴 시퀀스 데이터의 장기 의존성 문제를 해결하기 위해 고안됨
- 기존 RNN이 갖는 기울기 소실(*gradient vanishing*) 문제를 게이트 기반 구조(입력 게이트, 망각 게이트, 출력 게이트)와 메모리 셀(*Cell State*)로 효과적으로 완화
- 기억 셀을 통해 중요 정보를 오랜 기간 유지하며, 필요 없는 정보는 잊는 구조를 갖춰서 긴 시퀀스의 패턴 학습에 유리
- 자연어 처리, 시계열 데이터 분석, 음성 인식 등 다양한 분야에서 활용됩니다.
- 단점
 - 모델 복잡성 및 계산 비용 증가 : 게이트 구조 때문에 학습과 추론 속도가 느리고 리소스를 더 사용함
 - 과적합 가능성 : 복잡한 모델 구조로 인해 데이터가 적으면 과적합 위험
 - 학습시간 증가 및 하이퍼파라미터 튜닝 필요 : 하이퍼파라미터 조절과 학습 속도 조절이 까다로움