

ML 리뷰(1)-개요

머신러닝이란?

왜 머신러닝을 사용하나요?

머신러닝의 분류

지도학습(Supervised learning)

비지도학습(Unsupervised learning)

준지도학습(Semi-supervised learning)

자기 지도 학습(self-supervised learning)

강화 학습(reinforcement learning)

머신러닝 모델 기반 학습의 예시

머신러닝 프로젝트 과정 요약

테스트와 검증

머신러닝의 한계

데이터의 효과

충분하지 않은 양의 훈련 데이터

대표성 없는 훈련 데이터

낮은 품질의 데이터

특성 공학(feature engineering)

훈련 데이터 과대적합

규제(regularization)

훈련 데이터 과소적합

요약

머신러닝이란?

- 머신러닝은 데이터에서 학습하도록 컴퓨터를 프로그래밍하는 과학(또는 예술)

머신러닝은 명시적인 프로그래밍 없이 컴퓨터가 학습하는 능력을 갖추게 하는 연구 분야

- 아서 새뮤얼(Arthur Samuel), 1959

어떤 작업 T 에 대한 컴퓨터 프로그램의 성능을 P 로 측정했을 때 경험 E 로 인해 성능이 향상됐다면, 이 컴퓨터 프로그램은 작업 T 와 성능 측정 P 에 대해 경험 E 로 학습한 것

- 톰 미첼(Tom Mitchell), 1997

- 스팸 필터는 (사용자가 스팸이라고 지정한) 스팸 메일과 일반 메일의 샘플을 이용해 스팸 메일 구분법을 배울 수 있는 머신러닝 프로그램의 하나

- 기본 용어
 - 훈련 세트(training set): 시스템이 학습하는 데 사용하는 샘플
 - 훈련 사례(training instance) 혹은 샘플(sample): 각 훈련 데이터
 - 모델(model): 머신러닝 시스템에서 학습하고 예측을 만드는 부분
 - 신경망(neural network), 랜덤 포레스트(random forest)
 - 작업 T: 새로운 메일이 스팸인지 구분하는 것
 - 경험 E: 훈련 데이터(training data)
 - 성능 측정 P: 직접 정의해야 하며, 이 성능 측정을 정확도(accuracy)라고 부르며 분류 작업에 자주 사용


왜 머신러닝을 사용하나요?

- 전통적 프로그래밍 기법으로는 규칙이 점점 길고 복잡해지므로 유지 보수하기 매우 힘들




전통적인 접근 방법

- 프로그램이 훨씬 짧아지고 유지 보수하기 쉬우며 대부분 정확도가 더 높음
 - 기존 머신러닝 기법에 기반을 둔 스팸 필터는 일반 메일에 비해 스팸에 자주 나타나는 패턴을 감지하여 어떤 단어와 구절이 스팸 메일을 판단하는 데 좋은 기준인지 자동으로 학습




머신러닝 접근 방법

- 자동으로 변화에 적응
 - 머신러닝 기반의 스팸 필터는 사용자가 스팸으로 지정한 메일에 유독 'For U'가 자주 나타나는 것을 자동으로 인식하고 별도의 작업을 하지 않아도 이 단어를 스팸으로 분류



자동으로 변화에 적응

- 데이터 마이닝(data mining)
 - 대용량의 데이터를 분석하여 숨겨진 패턴을 발견



머신러닝을 통해 학습

- 머신러닝의 강점 분야
 - 기존 솔루션으로는 많은 수동 조정과 규칙이 필요한 문제
 - 머신러닝 모델이 코드를 간단하게 만들고 전통적인 방법보다 더 잘 수행
 - 전통적인 방식으로는 해결 방법이 없는 복잡한 문제
 - 가장 뛰어난 머신러닝 기법으로 해결 방법을 찾음
 - 유동적인 환경
 - 머신러닝 시스템은 새로운 데이터로 쉽게 재훈련할 수 있어 항상 최신 상태를 유지
 - 복잡한 문제와 대량의 데이터에서 인사이트 얻기
- 어플리케이션 사례
 - 생산 라인에서 제품 이미지를 분석해 자동으로 분류하기
 - 뇌를 스캔하여 종양 진단하기
 - 자동으로 뉴스 기사 분류하기
 - 토론 포럼에서 부정적인 코멘트를 자동으로 구분하기
 - 긴 문서를 자동으로 요약하기
 - 챗봇 또는 개인 비서 만들기
 - 여러 가지 성과 자료를 바탕으로 회사의 내년도 수익 예측하기
 - 음성 명령에 반응하는 앱 만들기
 - 신용카드 부정 거래 감지하기

- 구매 이력을 기반으로 고객을 나누고 각 집합마다 다른 마케팅 전략을 계획하기
- 고차원의 복잡한 데이터셋을 명확하고 의미 있는 그래프로 표현하기
- 과거 구매 이력을 기반으로 고객이 관심을 가질 수 있는 상품 추천하기
- 지능형 게임 봇 만들기

머신러닝의 분류

머신러닝 시스템을 학습하는 동안의 지도 형태나 정보량에 따라 분류


지도학습(Supervised learning)

- Dataset = Data + Label
- 알고리즘에 주입하는 훈련 데이터에 레이블(label)이라는 원하는 답이 포함
 - 분류(classification) – 스팸 필터



스팸 분류를 위한 레이블된 훈련 세트

- 회귀(regression) - (주행 거리, 연식, 브랜드 등)을 사용해 중고차 가격 같은 타겟(target) 수치를 예측



회귀 문제 : 주어진 입력 특성으로 값을 예측


비지도학습(Unsupervised learning)

- Dataset = Data + Label
- 훈련 데이터에 레이블이 없음
 - 시스템이 아무런 도움 없이 학습



비지도학습에서 레이블이 없는 훈련 세트

- 계층 군집(hierarchical clustering) 알고리즘을 사용하여 각 그룹을 더 작은 그룹으로 세분화



- K-Means Clustering


- 데이터를 미리 정한 K개의 그룹(클러스터)으로 나누는 알고리즘으로 데이터의 구조를 파악하고 그룹화하는 데 매우 널리 사용되는 기본적인 군집화 알고리즘

- 동작 원리


- 사용자가 원하는 클러스터 개수 K를 먼저 지정
- 데이터에서 K개의 중심점(centroid)을 임의로 선택
- 각 데이터 포인트를 가장 가까운 중심점에 할당하여 그룹 생성
- 각 그룹에 속한 데이터의 평균값으로 중심점을 다시 계산
- 데이터 할당과 중심점 계산을 반복하여 더 이상 변화가 없을 때까지 진행

- 특징

- 데이터의 라벨이 없어도 유사한 특성을 가진 데이터끼리 자동으로 그룹화할 수 있음
- 알고리즘이 단순하고 계산 효율이 높아 대규모 데이터에도 적용이 쉬움
- 시장 세분화, 이미지 분류, 문서 클러스터링 등 다양한 분야에서 활용




- 시각화(visualization) / 차원 축소(dimensionality reduction) / 특성 추출(feature extraction)



의미 있는 군집을 강조한 t-SNE 시각화의 예

- 이상치 탐지(outlier detection) / 특이치 탐지(novelty detection) / 연관 규칙 학습 (association rule learning)



준지도학습(Semi-supervised learning)

- 지도학습 + 비지도학습
- 레이블이 일부만 있는 데이터를 다루는 알고리즘
- Pseudo-labeling
 - 라벨이 없는 데이터(unlabeled data)에 대해 모델이 예측한 결과를 임시 라벨(pseudo label)로 활용하여 추가 학습에 사용하는 방법
 - 학습 방법
 - 먼저, 소량의 라벨이 있는 데이터(labeled data)로 모델을 학습
 - 학습된 모델을 이용해 라벨이 없는 데이터에 대해 예측을 수행하고, 예측 결과 중 신뢰도가 높은 값을 임시 라벨(pseudo label)로 부여
 - 이렇게 생성된 pseudo-labeled 데이터와 원래의 labeled 데이터를 합쳐 모델을 다시 학습
 - 이 과정을 반복하면, 라벨이 없는 데이터도 학습에 활용할 수 있어 데이터 부족 문제를 완화하고 모델의 성능을 높일 수 있음
 - 특징
 - 적은 양의 라벨 데이터만으로도 더 많은 데이터를 효과적으로 활용할 수 있음

- 하지만, 초기 모델이 부정확할 경우 잘못된 pseudo label이 누적되어 전체 모델 성능에 악영향을 줄 수 있으므로 주의가 필요함
- 이미지 분류, 자연어 처리 등 다양한 분야에서 데이터 라벨링 비용을 줄이고 성능을 높이기 위해 널리 사용
- Pseudo-labeling은 간단하면서도 강력한 준지도 학습 방법으로, 실제 산업 및 연구 현장에서 많이 활용되고 있음

자기 지도 학습(self-supervised learning)


- 레이블이 전혀 없는 데이터셋에서 레이블이 완전히 부여된 데이터셋을 생성
 - 레이블이 없는 이미지로 구성된 대량의 데이터셋이 있다면 각 이미지의 일부분을 랜덤하게 마스킹(masking)하고 모델이 원본 이미지를 복원하도록 훈련
 - 훈련하는 동안 마스킹된 이미지는 모델의 입력으로 사용되고 원본 이미지는 레이블로 사용




자기 지도 학습의 예 : 입력(왼쪽)과 타겟(오른쪽)

강화 학습(reinforcement learning)

- 에이전트(agent) - 학습하는 시스템
 - 환경(environment)을 관찰해서 행동(action)을 실행하고 그 결과로 보상(reward) 또는 벌점(penalty) 부과
- 정책(policy)
 - 시간이 지나면서 가장 큰 보상을 얻기 위한 최상의 전략을 스스로 학습
 - 정책은 주어진 상황에서 에이전트가 어떤 행동을 선택해야 할지 정의



1. 관찰
2. 정책에 따라 행동을 선택



3. 행동 실행!
4. 보상이나 벌점을 받음




5. 정책 수정(학습 단계)
6. 최적의 정책을 찾을 때까지 반복

강화학습

머신러닝 모델 기반 학습의 예시

돈이 사람을 행복하게 만드는지 알아본다고 가정(OECD, 세계은행 통계 활용)


국가	1인당 GDP(US 달러)	삶의 만족도
튀르키예	28,384	5.5
헝가리	31,008	5.6
프랑스	42,026	6.5
미국	60,236	6.9
뉴질랜드	42,404	7.3
호주	48,698	7.3
덴마크	55,938	7.6




- 모델 선택(model selection)
 - 1인당 GDP라는 특성 하나를 가진 삶의 만족도에 대한 선형 모델(linear model)을 선택
 - 이 모델은 두 개의 모델 파라미터(model parameter) θ_0 와 θ_1 를 가짐
 - 측정 지표 정의
 - 효용 함수(utility function) 또는 적합도 함수(fitness function)
 - 비용 함수(cost function)
 - 훈련(training)
 - 알고리즘에 훈련 데이터를 공급하여 데이터에 가장 잘 맞는 선형 모델의 파라미터를 찾음
 - $\theta_0 = 3.75$
 - $\theta_1 = 6.78 \times 10^{-5}$

식 1-1 간단한 선형 모델

$$\text{삶의_만족도} = \theta_0 + \theta_1 \times \text{1인당_GDP}$$



- 최적화한 선형 모델
 - OECD 데이터에 없는 키프로스(Cyprus) 사람들이 얼마나 행복한지 알아보기 위해 이 모델을 사용
 - 키프로스의 1인당 GDP를 보면 37,655달러이므로 이를 모델에 적용해 $3.75 + 37,655 \times 6.78 \times 10^{-5} = 6.30$ 이라는 삶의 만족도를 계산



훈련데이터에 최적인 선형 모델

머신러닝 프로젝트 과정 요약

- 데이터 분석
- 모델 선택
- 훈련 데이터로 모델을 훈련
 - 학습 알고리즘이 비용 함수를 최소화하는 모델 파라미터를 찾음
- 잘 일반화되기를 기대하면서 새로운 데이터에 모델을 적용해 예측 - 추론(inference)


테스트와 검증

- 훈련 세트와 테스트 세트 두 개로 나누어 검증
- 데이터의 80%를 훈련에 20%는 테스트용으로 분리하며, 데이터셋 크기에 따라 비율이 다름
 - 훈련 세트를 사용해 모델을 훈련하고 테스트 세트를 사용해 모델을 테스트
 - 새로운 샘플에 대한 오류 비율: 일반화 오차 또는 외부 샘플 오차
 - 테스트 세트에서 모델을 평가함으로써 이 오차에 대한 추정값으로, 이전에 본 적이 없는 새로운 샘플에 모델이 얼마나 잘 작동할지 예측
 - 훈련 오차가 낮지만(즉, 훈련 세트에서 모델의 오차가 적음) 일반화 오차가 높다면 이는 모델이 훈련 데이터에 과대적합되었다는 뜻

머신러닝의 한계

데이터의 효과

- 충분한 데이터가 주어지면 아주 간단한 모델을 포함하여 여러 다른 머신러닝 알고리즘이 복잡한 자연어 중의성 해소(disambiguation) 문제를 거의 비슷하게 잘 처리한다는 사실




알고리즘 대비 데이터의 중요성

충분하지 않은 양의 훈련 데이터

- 머신러닝 알고리즘이 잘 작동하려면 데이터가 많아야 함
- 간단한 문제에서도 수천 개의 데이터가 필요하고 이미지나 음성 인식 같은 복잡한 문제라면 수백만 개가 필요

대표성 없는 훈련 데이터

- 일반화가 잘되려면 훈련 데이터가 일반화하고 싶은 새로운 사례를 잘 대표하는 것이 중요
- 샘플이 작으면 샘플링 잡음(sampling noise, 우연에 의한 대표성 없는 데이터) 발생
- 매우 큰 샘플도 표본 추출 방법이 잘못되면 대표성을 띠지 못할 수 있음 - 샘플링 편향(sampling bias)



대표성이 더 큰 훈련 샘플

낮은 품질의 데이터

훈련 데이터 정제가 필요한 경우


- 일부 샘플이 이상치라는 게 명확하면 간단히 해당 샘플들을 무시하거나 수동으로 잘못된 것을 고침
- 일부 샘플에 특성 몇 개가 빠져있다면(예: 고객 중 5%가 나이를 기록하지 않음) 이 특성을 모두 무시할지, 이 샘플을 무시할지, 빠진 값을 채울지(예: 평균 나이로 채움), 또는 이 특성을 넣은 모델과 제외한 모델을 따로 훈련시킬 것인지 결정

특성 공학(feature engineering)

- 특성 선택(feature selection) - 가지고 있는 특성 중에서 훈련에 가장 유용한 특성을 선택
- 특성 추출(feature extraction) - 특성을 결합하여 더 유용한 특성을 만듦
- 데이터 수집 - 새로운 데이터를 수집해 새 특성을 만듦

훈련 데이터 과대적합


- 모델이 훈련 데이터에는 너무 잘 맞지만 일반성이 떨어짐



훈련 데이터에 과대 적합된 사례

규제(regularization)

- 모델을 단순하게 하고 과대적합의 위험을 줄이기 위해 모델에 제약을 가하는 것
- 학습하는 동안 적용할 규제(regularization)의 양은 하이퍼파라미터(hyperparameter)가 결정



규제는 과대적합의 위험을 감소

훈련 데이터 과소적합

- 모델이 너무 단순해서 데이터의 내재된 구조를 학습하지 못할 때 발생
- 문제 해결
 - 모델 파라미터가 더 많은 강력한 모델을 선택
 - 학습 알고리즘에 더 좋은 특성을 제공(특성 공학)
 - 모델의 제약을 줄임(예: 규제 하이퍼파라미터를 감소시킴)

요약

- 머신러닝은 명시적인 규칙을 코딩하지 않고 기계가 데이터로부터 학습하여 어떤 작업을 더 잘하도록 만드는 것
- 학습 알고리즘이 모델 기반이면 훈련 세트에 모델을 맞추기 위해 모델 파라미터를 조정하고(즉, 훈련 세트에서 좋은 예측을 만들기 위해), 새로운 데이터에서도 좋은 예측을 만들 거라 기대
- 훈련 세트가 너무 작거나, 대표성이 없거나, 잡음이 많고 관련없는 특성으로 오염되어 있다면 시스템이
잘 작동하지 않음
 - GIGO(쓰레기가 들어가면 쓰레기가 나옴)
 - 모델이 너무 단순하거나(과소적합된 경우) 너무 복잡하지 않아야 함(과대적합된 경우)