

ML 리뷰(2)-원리

회귀(Regression)

선형회귀(Linear Regression)

단순선형회귀(Simple Linear Regression)

손실함수(Cost function) 또는 Loss function)

손실함수(예시)

손실함수의 종류

경사하강법(Gradient descent)

경사하강법 알고리즘

다중선형회귀(Multiple Linear Regression)

참고

최적화


미분(Differential Calculus)

편미분(Partial Derivatives)

기울기(Gradient)


회귀(Regression)

- 두 가지 목적으로 사용
 - (예측 측면) 새로운 입력 값에 대한 출력 값을 예측하는 것
 - 예시: 키가 170cm인 사람의 몸무게는 얼마인가?
 - (해석 또는 관계 측면) 입력 값에 대한 출력 값의 변화는 어떻게 되는가?
 - 예시: 키가 큰 사람은 몸무게가 무거운 가?
- 예시 : 집 값 예측
 - Relation : 집 값(Price)와 집 크기(Size)와의 관계는 어떻게 되는가?
 - Prediction : 집 크기가 1,202일 때, 예상되는 집 가격은 어떻게 되는가?




집 크기와 가격

- 회귀(Regression)
 - 독립 변수(Independent variable)(x)와 종속 변수(Dependent variable)(y)간의 관계를 분석
 - 새로운 입력 값(Input)(x)에 대한 출력 값(Output)(y)을 예측(Prediction)
 - 종속 변수(y)에 대한 독립 변수(x)의 효과를 이해하는 것



회귀 : x (입력값)와 y (출력값)와의 관계를 정의(빨간선)

- 회귀에서의 학습
 - 입력 값이 주어졌을 때, 적합한 출력 값을 내는 함수(Function)를 찾는 과정
 - 독립변수와 종속변수간의 관계를 표현하는 함수를 찾는 과정



회귀에서의 학습 : 함수를 찾는 과정

- 상관관계(correlation) ≠ 인과관계
 - 회귀는 상관관계를 찾는 것으로 인과관계를 의미하지 않는다
 - 따라서 해석할 때, 인과관계로 해석해서는 안된다.

선형회귀(Linear Regression)

Linear + Regression = 선을 그어 + 값을 예측

- 데이터를 일반화하는 선을 찾는다.
- 그 선을 이용해 새로운 데이터를 예측한다.

단순선형회귀(Simple Linear Regression)

- 입력 값의 차원이 1개 일 때, 아래와 같은 식(함수 또는 모델)을 **단순 선형 회귀**라고 한다.

$$y_i \approx \underline{f(x_i)} = f_{\mathbf{w}}(x_i) = w_0 + w_1 x_i$$


$f(x_i)$ 를 $\hat{y}_i$ 으로 표기하기도 함.

* $\mathbf{x}_i = [x_{i1} \ x_{i2} \ x_{i3} \ \dots \ x_{ij} \ \dots \ x_{id}]^T \in \mathbb{R}^d$ 에서 차원 d 가 1로
 $\mathbf{x}_i = [x_{i1}] = x_i \in \mathbb{R}$ 로 하자.
 $\mathbf{w} = [w_0 \ w_1]^T$ 라고 하자. (단순 선형 회귀)

- 여기서, $\mathbf{w} = [w_0 \ w_1]^T$ 는 파라미터(매개변수)들의 벡터로 2개의 파라미터를 갖는다.

→ 또 다른 말로 가중치라고 하기도 함

단순 선형 회귀 모델 $f_{\mathbf{w}}(x_i) = w_0 + w_1 x_i$ 는 독립변수와 종속변수간의 관계를 아래의 그림과 같이 표현



단순 선형 회귀

손실함수(Cost function) 또는 Loss function)


▪ 집 값(Price)에 대한 훈련데이터셋

크기(단위 : feet ²)(x)	가격 (단위 : 1,000\$)
2,104	(y) 460
1,416	232
1,534	315

▪ 모델은 $y_i \approx f(x_i) = f_w(x_i) = w_0 + w_1 x_i$ 로 즉 단순 선형 회귀 모델로 선정.

훈련 데이터가 주어졌을 때, $\mathbf{w} = [w_0 \ w_1]^T$ 의 값을 어떻게 설정할 수 있을까?

▪ 핵심 아이디어 : 훈련데이터셋 $\{(x_i, y_i)\}_{i=1}^N$ 을 이용해서 $f_w(x_i)$ 가 y_i 값에 가깝도록, $\mathbf{w} = [w_0 \ w_1]^T$ 을 정하는 것이다.



$$L(\mathbf{w}) = \frac{1}{N} \sum_{i=1}^N \{y_i - f_w(x_i)\}^2$$

- N : 입력값의 수
- $f_w(x_i)$: i 번째 예측값($= \hat{y}_i$)
- y_i : i 번째 실제값

$$\mathbf{w}^* = \arg \min_{\mathbf{w}} L(\mathbf{w}) = \arg \min_{\mathbf{w}} \frac{1}{N} \sum_{i=1}^N \{y_i - f_w(x_i)\}^2$$

- $\mathbf{w}^*$: $\arg \min_{\mathbf{w}} L(\mathbf{w})$ 함수의 값으로, 손실 함수 $L(\mathbf{w})$ 를 최소화하는 모델의 파라미터 값이다. $\mathbf{w}^* = [w_0^* \ w_1^*]^T$ 이다.

- 손실 함수 (비용 함수, 훈련 목적 함수 등)는 모델의 파라미터 $\mathbf{w} = [w_0 \ w_1]^T$ 를 학습할 때 사용된다.
- 손실 함수 $L(\mathbf{w})$ 를 작게 할수록, 훈련 데이터에 대해 모델이 예측한 출력 값 $f_{\mathbf{w}}(x_i)$ 이 실제 값 y_i 과 유사하다는 것을 의미한다.

손실함수(예시)

- Model:

$$f_{\mathbf{w}}(x) = w_0 + w_1 x$$

- Parameters:

$$\mathbf{w} = [w_0 \ w_1]^T$$

- Cost function:

$$L(\mathbf{w}) = \frac{1}{N} \sum_{i=1}^N (y_i - f_{\mathbf{w}}(x_i))^2$$

- Goal:

$$\mathbf{w}^* = \underset{\mathbf{w}}{\operatorname{argmin}} L(\mathbf{w})$$

- Model:

$$f_{\mathbf{w}}(x) = w_1 x \quad (w_0 = 0)$$

- Parameters:



$$w_1$$



- Cost function:

$$L(w_1) = \frac{1}{N} \sum_{i=1}^N (y_i - f_{w_1}(x_i))^2$$


- Goal:

$$w_1^* = \underset{w_1}{\operatorname{argmin}} L(w_1)$$





$$* \mathbf{w} = [w_0 \ w_1]^T$$



손실함수의 종류

- 평균 제곱 오차 (Mean square error, MSE)

$$\frac{1}{N} \sum_{i=1}^N (y_i - f_w(x_i))^2$$


- 평균 절대 오차 (Mean absolute error, MAE)

$$\frac{1}{N} \sum_{i=1}^N |y_i - f_w(x_i)|$$


* 이외에도 다양한 손실함수가 존재하지만 대표적으로 MSE, MAE가 있다.

경사하강법(Gradient descent)

- 여러 종류의 문제에서 최적의 해법을 찾을 수 있는 일반적인 최적화 알고리즘
 - 빨리 골짜기로 내려가는 좋은 방법은 가장 가파른 길을 따라 아래로 내려가는 것
 - 파라미터 벡터 θ 에 대해 비용 함수의 현재 그레이디언트(gradient)를 계산
 - 그레이디언트가 감소하는 방향으로 진행하여 그레이디언트가 0이 되면 최솟값에 도달




- 학습률 하이퍼파라미터
 - 학습률이 너무 작으면 알고리즘이 수렴하기 위해 반복을 많이 진행해야 하므로 시간이 오래 걸림
 - 학습률이 너무 크면 알고리즘을 더 큰 값으로 발산하게 만들어 적절한 해법을 찾지 못함



- 경사 하강법의 두 가지 문제점
 - 알고리즘이 왼쪽에서 시작하면 전역 최솟값(global minimum)보다 덜 좋은 지역 최솟값(local minimum)에 수렴

- 오른쪽에서 시작하면 평탄한 지역을 지나기 위해 시간이 오래 걸리고 일찍 멈추게 되어 전역 최소값에 도달하지 못함




▪ 모델의 학습 방법으로

손실함수 $L(\mathbf{w})$ 가 주어졌을 때, 손실함수를 가장 최소화하는 파라미터 $\mathbf{w}^* = [w_0^* \ w_1^*]^T$ 를 찾는 것이다.

$$\mathbf{w}^* = \underset{\mathbf{w}}{\operatorname{argmin}} L(\mathbf{w})$$

- 가장 간단한 방법으로, 파라미터 $\mathbf{w} = [w_0 \ w_1]^T$ 에 넣을 후보 값을 몇 개 정하고, 각 후보 값을 모델에 학습시켰을 때, 손실함수값이 가장 작은 파라미터를 선정한다. 하지만 이 방법은 후보 값을 정하는 것이 쉽지 않다.


- 손실함수 $L(\mathbf{w})$ 가 주어졌을 때, $\mathbf{w}^* = \underset{\mathbf{w}}{\operatorname{argmin}} L(\mathbf{w})$ 를 찾는 것이 목표이다.



▪ 손실함수 $L(\mathbf{w})$ 가 주어졌을 때, $\mathbf{w}^* = \underset{\mathbf{w}}{\operatorname{argmin}} L(\mathbf{w})$ 를 찾는 것이 목표이다.

▪ 기울기(Gradient) 이용 : (한 지점에서의) 기울기는 함수의 접선 기울기이다. 이 기울기는 함수를 가장 최대 증가시키는 방향을 나타낸다.

따라서, 현재 지점($\mathbf{w} = [w_0 \ w_1]^T$)에서의 음의 기울기 방향 $-\frac{\partial}{\partial \mathbf{w}} L(\mathbf{w})$ 은 손실 함수 $L(\mathbf{w})$ 를 최대로 감소시키는 방향을 의미하고 경사하강(gradient descent)의 방향이라고 한다.



▪ 절차

(1) 초기값 $\mathbf{w} = [w_0 \ w_1]^T$ 에서 시작한다. (예를 들어, $w_0 = 0, w_1 = 1$)


(2) 종료조건을 만족할 때까지

$L(\mathbf{w})$ 를 감소하는 방향으로 $\mathbf{w} = [w_0 \ w_1]^T$ 를 반복적으로 업데이트 한다.

Q1: $\mathbf{w}$ 는 어디에서 시작하는가?

Q2: 어느 방향으로 $\mathbf{w}$ 를 업데이트 하는가?


Q3: $\mathbf{w}$ 를 업데이트 할 때, 얼마나 움직이는가?



Q1: w 는 어디에서 시작하는가? → 초기화(Initialization)

Q2: 어느 방향으로 w 를 업데이트 하는가? → 기울기(Gradient)

Q3: w 를 업데이트 할 때, 얼마큼 움직이는가? → 학습률(Learning rate)





■ 경사하강법 알고리즘

– 종료조건을 만족할 때까지 아래 과정을 반복한다. ← 예시) for loop, while loop, ...

$$\left\{ \begin{array}{l} w_0 \leftarrow w_0 - \alpha L \frac{\partial}{\partial w_0} (w_0, w_1) \\ w_1 \leftarrow w_1 - \alpha L \frac{\partial}{\partial w_1} (w_0, w_1) \end{array} \right\}$$

← 학습률 ← 기울기
← w의 현재 상태





경사하강법 예시

경사하강법 알고리즘

- 최적화 알고리즘 비교
 - m (훈련 샘플 수), n (특성 수)

알고리즘	m 이 클 때	외부 메모리 학습 지원	n 이 클 때	하이퍼 파라미터 수	스케일 조정 필요	사이킷런
정규 방정식	빠름	No	느림	0	No	N/A
SVD	빠름	No	느림	0	No	LinearRegression
배치 경사 하강법	느림	No	빠름	2	Yes	N/A
확률적 경사 하강법	빠름	Yes	빠름	≥ 2	Yes	SGDRegressor
미니배치 경사 하강법	빠름	Yes	빠름	≥ 2	Yes	N/A

다중선형회귀(Multiple Linear Regression)

크기(feet ²)	방 개수	층 개수	집 연식	집 가격(1,000달러 기준)
2,105	5	1	40	469
1,325	3	3	30	230
1,425	3	2	20	300
872	2	1	40	170
⋮	⋮	⋮	⋮	⋮

$\mathbf{x}_i = [x_{i1} \ x_{i2} \ \cdots \ x_{ij} \ \cdots \ x_{id}]^T$

y_i


• 매핑 함수 (Mapping Function)

* $\mathbf{x}_i = [x_{i1} \ x_{i2} \ x_{i3} \ \dots \ x_{ij} \ \dots \ x_{id}]^T \in \mathbb{R}^d$ 에서 차원 d 가 1로


- 단순 선형 회귀 : $f_w(\mathbf{x}_i) = w_0 + w_1 x_i$ $\mathbf{x}_i = [x_{i1}] = x_i \in \mathbb{R}$ 로 하자. (i 의 의미는 i 번째 데이터셋)
 $\mathbf{w} = [w_0 \ w_1]^T$ 라고 하자. (단순 선형 회귀)

- 다중 선형 회귀 : $f_w(\mathbf{x}_i) = w_0 + w_1 x_{i1} + w_2 x_{i2} + w_3 x_{i3} + w_4 x_{i4}$

e.g., $f_w(\mathbf{x}_i) = 80 + 0.1 x_{i1} + 0.01 x_{i2} + 5 x_{i3} - 2 x_{i4}$




비선형 데이터셋



다중 선형회귀 모델의 예측

- 300차 다항 회귀 모델을 이전 훈련 데이터에 적용
 - 이 고차 다항 회귀 모델은 심각하게 훈련 데이터에 과대적합
 - 반면에 선형 모델은 과소적합
 - 이 경우 가장 일반화가 잘되는 모델은 2차 다항 회귀



고차 다항회귀

참고

최적화

- 머신러닝에서는 모델의 예측값과 실제값의 차이를 최소화하거나, 분류 정확도를 최대화하는 등의 목표가 부여됨
 - 학습 과정에서 부여되는 목표를 정량적으로 표현한 것을 목적함수(Objective function)이라고 함
 - 최적화(Optimization) 과정을 통해 원하는 목적함수를 달성하는 모델의 파라미터 값을 탐색
 - 최소화 문제에서 목적 함수는 비용 함수(cost function) 또는 손실 함수(loss function) 또는 오류 함수(error function)라고 하기도 한다.
- 목적 함수와 모델 파라미터의 결정 방식은 매우 다양
 - 머신러닝에서는 주어진 학습 데이터에 기반하여 가장 바람직한 목적 함수 값을 달성하는 모델의 파라미터 값을 찾고자 함
- 경사하강법(Gradient descent)
 - 기울기(Gradient)를 이용하여 모델의 파라미터 값을 업데이트하는 방법
 - 자세한 내용은 다음시간에 소개

미분(Differential Calculus)

- 머신러닝에서 모델 학습시 경사하강법이나 오차역전파 등에서 미분이 사용된다.

▪ 함수 $f: \mathbb{R} \rightarrow \mathbb{R}$ 의 도함수(derivative)는 다음과 같이 정의된다.

$$f'(x) = \frac{d}{dx} f(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$$

- $f'(a)$ 가 극한 값이 존재하면, f 는 a 에서 미분 가능하다고 한다.
- $f'(c)$ 가 $\forall c \in [a, b]$ 에 대해 존재하면 f 는 이 구간에서 미분 가능하다.
 - 미분 $f'(x)$ 을 x 에 대한 $f(x)$ 의 순간 변화율로 해석할 수도 있다.
- 기호 $\frac{d}{dx}$, D , D_x 는 미분 연산을 나타내는 미분 연산자(differentiation operators)이다.
- x 가 독립 변수이고 y 가 종속 변수인 $y = f(x)$ 가 주어지면 다음 식은 동일하다.

$$f'(x) = f' = \frac{dy}{dx} = \frac{df}{dx} = \frac{d}{dx} f(x) = Df(x) = D_x f(x)$$

- 자주 사용되는 미분식

상수값에 대한 미분	$\frac{d}{dx}c = 0$
선형 함수에 대한 미분	$\frac{d}{dx}(ax) = a$
거듭제곱 ^{Power} 에 대한 미분	$\frac{d}{dx}x^n = nx^{n-1}$ (n 은 양의 정수)
지수 함수에 대한 미분	$\frac{d}{dx}e^x = e^x$
로그에 대한 미분	$\frac{d}{dx}\log(x) = \frac{1}{x}$
덧셈 규칙에 대한 미분	$\frac{d}{dx}(g(x) + h(x)) = \frac{d}{dx}g(x) + \frac{d}{dx}h(x)$
곱셈 규칙에 대한 미분	$\frac{d}{dx}(g(x)h(x)) = g(x)\left(\frac{d}{dx}h(x)\right) + \left(\frac{d}{dx}g(x)\right)h(x)$
체인룰 ^{Chain rule}	$\frac{d}{dx}g(h(x)) = \frac{d}{dh}g(h(x)) \frac{d}{dx}h(x)$

자주 사용되는 미분식

편미분(Partial Derivatives)

- 머신러닝에서 편미분은 중요하다. 다중퍼셉트론의 오차역전파 시 사용된다.

■ 여러 개의 변수가 정의역을 구성하는 함수를 다변량 함수(Multivariate functions)라고 한다.

■ $y = f(\mathbf{x}) = f(x_1, x_2, \dots, x_n)$ 를 n 개의 변수가 있는 다변량 함수라고 한다.

– 입력은 n 차원 벡터 $\mathbf{x} = [x_1 \ x_2 \ \dots \ x_n]^T$ 이고 출력은 스칼라 y 이다.

– $f: \mathbb{R}^n \rightarrow \mathbb{R}$

■ i 번째 매개변수 x_i 에 대한 y 의 편미분(Partial derivative)은 다음과 같다.

$$\frac{\partial y}{\partial x_i} = \lim_{h \rightarrow 0} \frac{f(x_1, x_2, \dots, \mathbf{x_i+h}, \dots, x_n) - f(x_1, x_2, \dots, x_i, \dots, x_n)}{h}$$

■ $\frac{\partial y}{\partial x_i}$ (∂y 는 partial y 라고 읽는다.)의 계산

– $x_1, x_2, \dots, x_{i-1}, x_{i+1}, \dots, x_n$ 을 상수로 취급하고 x_i 에 대해서만 y 의 도함수를 계산한다.

■ 아래의 표현은 모두 동일한 상황을 의미

$$\frac{\partial y}{\partial x_i} = \frac{\partial f}{\partial x_i} = \frac{\partial}{\partial x_i} f(\mathbf{x}) = f_{x_i} = D_i f = D_{x_i} f$$

기울기(Gradient)

- 머신러닝에서 경사하강법시 손실함수에 대한 가중치의 기울기를 계산한다.

■ 기울기(Gradient)

- n 차원 입력 벡터 $\mathbf{x} = [x_1 \ x_2 \ \dots \ x_n]^T$ 에 대한 다변량 함수 $f(\mathbf{x})$ 의 기울기는 아래와 같이 편미분 결과로 구성된 벡터로 정의된다 :

$$\nabla f(\mathbf{x}) = \left[\frac{\partial f(\mathbf{x})}{\partial x_1} \ \frac{\partial f(\mathbf{x})}{\partial x_2} \ \dots \ \frac{\partial f(\mathbf{x})}{\partial x_n} \right]^T$$

■ $\nabla f(\mathbf{x})$ 표기법

- 그레디언트의 표기 : 그리스 문자 ∇ ("nabla"로 발음)
 - $\nabla f(\mathbf{x})$ 는 "벡터 $\mathbf{x}$ 에 대한 f 의 기울기"라고 지칭.
- 머신러닝에서 기울기는 모델의 파라미터를 업데이트하는 과정에서 중요하게 활용됨