

모델 성능 평가 지표

Evaluation Metrics

회귀(Regression)

분류(Classification)

MLP의 성능 향상을 위한 고려사항

(1) 하이퍼파라미터 튜닝

하이퍼파라미터

하이퍼파라미터 종류

(2) 은닉 층 개수

(3) 은닉 층의 뉴런 개수

Evaluation Metrics

모델의 목적에 따라 다양한 성능 평가 지표를 활용

회귀(Regression)

1. MAE (Mean Absolute Error, 평균 절대 오차)

- 실제값과 예측값의 차이의 절댓값을 모두 더한 뒤, 데이터 개수로 나눈 값입니다.
- 계산식:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_{true,i} - y_{pred,i}|$$

- 해석: 오차의 크기를 직관적으로 보여주며, 값이 작을수록 예측이 실제에 가깝다는 의미입니다.

2. MSE (Mean Squared Error, 평균 제곱 오차)

- 실제값과 예측값의 차이를 제곱해서 모두 더한 뒤, 데이터 개수로 나눈 값입니다.
- 계산식:

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_{true,i} - y_{pred,i})^2$$

- 해석: 큰 오차에 더 큰 패널티를 주며, 이상치(outlier)에 민감합니다.

3. RMSE (Root Mean Squared Error, 평균 제곱근 오차)

- MSE에 제곱근을 취한 값입니다.
- 계산식:

$$RMSE = \sqrt{MSE}$$

- 해석: MSE와 단위가 같아져 해석이 쉬우며, 값이 작을수록 좋습니다.

4. R² Score (결정계수)

- 모델이 실제값의 변동을 얼마나 잘 설명하는지 나타내는 지표입니다.
- 계산식:

$$R^2 = 1 - \frac{\sum (y_{true} - y_{pred})^2}{\sum (y_{true} - \bar{y})^2}$$

- 해석: 1에 가까울수록 모델의 설명력이 높고, 0에 가까우면 설명력이 낮습니다. 음수가 나올 수도 있습니다.

5. MAPE (Mean Absolute Percentage Error, 평균 절대 백분율 오차)


- 실제값과 예측값의 차이의 비율(%)을 평균한 값입니다.
- 계산식:

$$MAPE = \frac{100}{n} \sum_{i=1}^n \left| \frac{y_{true,i} - y_{pred,i}}{y_{true,i}} \right|$$

- 해석: 예측이 실제값에서 평균적으로 몇 % 정도 벗어났는지 알 수 있습니다.

- 실제값과 예측값의 차이를 수치로 나타내는 다양한 지표를 사용


- 결정계수(Coefficient of Determination or R-squared Score)를 주로 사용
 - 1에 가까울수록 모델의 설명력이 높고, 0에 가까우면 설명력이 낮음. 음수가 나올 수 있음




- MAE, MSE, RMSE, MAPE는 값이 작을수록 모델의 예측이 실제에 가깝다는 의미

분류(Classification)

- 혼동 행렬(Confusion Matrix)을 기반으로 여러 지표를 산출
- 모델이 예측한 값과 실제 값을 비교해, 얼마나 정확히 분류했는지 어떤 오류가 발생했는지 보여줌
- 혼동 행렬(Confusion Matrix) 구성
 - **TP (True Positive):** 실제 Positive를 Positive로 맞게 예측
 - **TN (True Negative):** 실제 Negative를 Negative로 맞게 예측
 - **FP (False Positive):** 실제 Negative를 Positive로 잘못 예측 (오류)
 - **FN (False Negative):** 실제 Positive를 Negative로 잘못 예측 (오류)



다층 퍼셉트론의 다중 분류 결과를 나타낸 혼동행렬



모델 테스트 결과

		예측값	
		Negative	Positive
실제값	Negative	TN	FP
	Positive	FN	TP

- True Positive(TP): 실제값이 양성인 테스트 데이터를 양성으로 예측(정답)
- False Positive(FP): 실제값이 음성인 테스트 데이터를 양성으로 예측(오답)
- True Negative(TN): 실제값이 음성인 테스트 데이터를 음성으로 예측(정답)
- False Negative(FN): 실제값이 양성인 테스트 데이터를 음성으로 예측(오답)

$$\text{Accuracy} = \frac{TP + TN}{TP + FP + FN + TN}$$

(정확도)

$$\text{Recall} = \frac{TP}{TP + FN}, \quad \text{Precision} = \frac{TP}{TP + FP}$$


(재현율) (정밀도)

$$\text{F1-score} = \frac{2 \cdot (\text{Precision} \cdot \text{Recall})}{(\text{Precision} + \text{Recall})}$$

• 주요 평가 지표

- Accuracy (정확도) : 전체 데이터 중 맞게 예측한 비율
 - 클래스 불균형 데이터에서는 신뢰도가 떨어질 수 있음
- Precision (정밀도) : 모델이 Positive로 예측한 것 중 실제 Positive 비율
 - False Positive를 얼마나 줄였는지 평가
- Recall (재현율, 민감도) : 실제 Positive 중 모델이 맞게 예측한 비율
 - False Negative를 얼마나 줄였는지 평가
- F1 Score : Precision과 Recall의 조화 평균
 - 불균형 데이터에서 모델 성능을 종합적으로 평가할 때 유용
- ROC Curve / AUC
 - ROC Curve : 이진 분류 모델의 성능을 평가하는 그래프로, 다양한 임계값 (threshold)에서의 모델 성능 변화를 시각화함

- AUC (Area Under the Curve) : ROC Curve 아래 면적을 의미
 - 값은 0과 1 사이이며, 1에 가까울수록 완벽한 분류기, 0.5는 무작위 추측 수준을 나타냄
 - 곡선 아래 면적이 클수록 좋은 모델



- X축: False Positive Rate (FPR, 거짓 양성 비율) = $\frac{FP}{FP+TN}$
- Y축: True Positive Rate (TPR, 재현율 또는 민감도) = $\frac{TP}{TP+FN}$

MLP의 성능 향상을 위한 고려사항

(1) 하이퍼파라미터 튜닝

하이퍼파라미터

- 모델의 구조와 학습 방식을 결정하는 사용자가 직접 설정하는 값
- 하이퍼파라미터는 모델의 성능에 큰 영향을 주므로, 여러 값을 실험하며 최적의 조합을 찾는 과정(튜닝)이 필요함

하이퍼파라미터 종류

1. Epoch(에포크)

- 전체 데이터셋을 모델이 몇 번 반복해서 학습할지 정하는 횟수

- 너무 적으면 과소적합, 너무 많으면 과적합 위험이 있음
- 대부분의 경우 훈련 반복 횟수는 튜닝할 필요가 없음. 대신 조기 종료를 사용

2. Batch Size(배치 크기)

- 한 번에 학습에 사용하는 데이터 샘플의 개수
- GPU RAM에 맞는 가장 큰 배치 크기 사용이 권장
- 크기가 크면 학습 속도는 빨라지지만, 메모리 사용량이 늘고 일반화가 어려울 수 있음. 작으면 학습이 느려지지만 일반화에 도움이 될 수 있음

3. Learning Rate(학습률)

- 가중치가 얼마나 빠르게(또는 천천히) 업데이트되는지 결정하는 값
- 너무 크면 학습이 불안정해지고, 너무 작으면 학습이 느려짐

4. Number of Layers(계층의 수)와 각 층의 뉴런 수

- 은닉층(hidden layer)과 각 층의 뉴런 개수는 모델의 복잡도 결정
- 층이 많고 뉴런이 많을수록 복잡한 패턴을 학습할 수 있지만, 과적합 위험도 커짐

5. Optimizer(최적화 알고리즘)

- 고전적인 평범한 미니배치 경사 하강법보다 더 좋은 옵티마이저를 선택하는 것(그리고 이 옵티마이저의 하이퍼파라미터를 튜닝하는 것)도 매우 중요
- 가중치 업데이트 방식을 결정 (예: SGD, Adam 등)

6. Activation Function(활성화 함수)

- 각 뉴런의 출력을 결정하는 함수로, 비선형성 부여 (예: ReLU, Sigmoid, Tanh 등)
- 일반적으로 ReLU 활성화 함수가 모든 은닉 층에 좋은 기본값
- 출력 층의 활성화 함수는 수행하는 작업에 따라 달라짐

7. Regularization(규제) 관련 파라미터

- 과적합을 방지하기 위한 드롭아웃 비율, L1/L2 패널티 등도 하이퍼파라미터에 포함

(2) 은닉 층 개수

- 복잡한 문제에서는 심층 신경망이 얇은 신경망보다 파라미터 효율성(parameter efficiency)이 훨씬 좋음
 - 실제 데이터는 계층 구조를 가진 경우가 많으므로 심층 신경망은 이런 면에서 유리
 - 아래쪽 은닉 층은 저수준의 구조를 모델링(여러 방향이나 모양의 선)

- 중간 은닉 층은 저수준의 구조를 연결해 중간 수준의 구조를 모델링(사각형, 원)
- 가장 위쪽 은닉 층과 출력 층은 중간 수준의 구조를 연결해 고수준의 구조를 모델링(얼굴)
- 계층 구조는 심층 신경망이 좋은 솔루션으로 빨리 수렴하게 도와줄 뿐만 아니라 새로운 데이터에 일반화되는 능력도 향상

(3) 은닉 층의 뉴런 개수

- 입력 층과 출력 층의 뉴런 개수는 해당 작업에 필요한 입력과 출력의 형태에 따라 결정
 - 예를 들어 MNIST는 $28 \times 28 = 784$ 개의 입력 뉴런과 10개의 출력 뉴런이 필요
- 은닉 층의 구성 방식은 일반적으로 각 층의 뉴런을 점점 줄여서 깔때기처럼 구성
 - 저수준의 많은 특성이 고수준의 적은 특성으로 합쳐질 수 있기 때문임
- 층의 개수와 마찬가지로 네트워크가 과대적합이 시작되기 전까지 점진적으로 뉴런 수를 늘릴 수 있음
 - 필요한 것보다 더 많은 층과 뉴런을 가진 모델을 선택한 다음, 과대적합되지 않도록 조기 종료나 규제 기법을 사용