

순환 신경망(RNN;Recurrent Neural Network)

정의

RNN 언어모델

순전파

역전파


기울기 소실 문제

RNN의 한계

vanishing gradient problem

정의

- 은닉층에서 나온 결과값이 다시 은닉층으로 돌아가 새로운 입력값과 연산을 수행하는 순환구조
- 완전연결층(Fully Connected Layer), **CNN**(Convolutional Neural Network)은 은닉층에서 나온 결과값이 출력층 방향으로 이동하지만, **RNN**은 은닉층으로 되돌아가 순환한다는 점에서 큰 차이가 있음




[그림 1] RNN 순환구조

- **RNN** 순환구조를 펼친 형태로 입력값 $\{x_0, x_1, \dots, x_t\}$ 를 순차적으로 입력했을 때 각 입력에 대응해 $\{h_0, \dots, h_t\}$ 가 출력됨
- **RNN**계층은 모두 같은 계층이고 출력 $\{h_0, \dots, h_k, \dots, h_t\}$ 를 각각 k 시점에서의 은닉 상태라고 함
- **RNN**의 구조는 시계열 데이터, 텍스트 데이터에 적합함

RNN 언어모델

- 'You say goodbye and I say hello'에서 각 단어의 다음에 나올 단어를 예측하고자 할때, 문장에서 임베딩 된 단어를 순차적으로 **RNN** 에 입력
- 이후 각 입력에 대응하는 은닉상태로 다음에 나올 단어를 예측함. 여기서 은닉상태는 해당 시점까지의 단어 정보를 나타냄
- 순전파와 역전파를 반복하며 모델을 학습시켜 최종적으로 각 단어 다음에 나올 단어를 완벽하게 예측하는 은닉상태를 갖는 것이 RNN의 목적임




[그림 2] RNN의 언어모델

- [그림 2]에서 You 라는 단어가 Embedding 계층을 거친 후 RNN에 입력되면, you의 은닉상태 h_{you} 를 출력하고 다음에 올 단어 say를 예측
- 은닉상태 h_{you} 는 다음 RNN 계층으로 들어가 say라는 단어가 임베딩된 형태와 연산합니다. 여기서 h_{you} 는 과거의 정보 'you'를 응집한 은닉 상태
- 다음 RNN 계층에서 나온 say의 은닉상태 h_{say} 는 과거의 정보 'You say'를 응집한 은닉 상태

- 이후 h_{say} 를 이용해 다음에 올 단어 goodbye를 예측함
- 이 과정이 RNN 학습, 순전파 과정입니다. 이후 역전파 과정을 거치며 예측 단어와 실제 단어를 비교하면서 가중치와 은닉상태를 업그레이드함.

순전파



[그림 3] RNN 순전파 과정


- say의 은닉상태인 h_{say} 와 hello가 임베딩된 벡터(x_{hello})가 RNN계층에 들어간 후 일련의 과정을 통해 hello의 은닉상태인 h_{hello} 와 y_{hello} 를 출력함
- 출력된 은닉상태는 다음 RNN 계층의 입력으로 이동함
- h_{hello} 는 hello를 비롯해 say, I 와 같이 그동안 이동해온 단어들의 정보를 갖고 있음
- y_{hello} 는 h_{hello} 가 변형된 형태로, hello의 다음 단어를 예측한 결과임

$$\begin{aligned}
 h_{hello} &= \tanh(h_{say}W_h + x_{hello}W_x + b) \\
 h_{row} &= h_{say}W_h + x_{hello}W_x + b \\
 y_{hello} &= w_y \times h_{hello} + b_y
 \end{aligned}$$

[그림 4] RNN 순전파 수식

- 가중치와 편향인 W_h , W_x , b 는 RNN계층별로 동일
- [그림 4]를 보면 h_{hello} 를 구하기 위해 h_{say} 와 W_h 를 곱하고 hello 를 임베딩한 단어벡터(x_{hello})와 W_x 를 곱한 후 편향(b)을 더함
- 이후 하이퍼볼릭탄젠트 함수($\tanh$)를 씌움

역전파



[그림 5] RNN의 역전파

- RNN에서 오차역전파는 RNN 계층에서 출력된 결과와 Y값의 차이를 반영해 가중치와 은닉상태를 업그레이드하는 과정임
- [그림5]에서 Softmax 이후 나오는 단어들의 예측 확률과 실제값의 오차를 Cross Entropy로 구함
- 이후 오차를 미분해 기울기 $\{dh_{\text{hello}}, dh_{\text{row}}, dh_{\text{say}}, dw_x, dx_{\text{hello}}, dw_h\}$ 를 구하고 각 가중치에 반영해 업그레이드하는 식으로 오차역전파가 진행
- 오차를 미분하는 과정에서 y에 대해 미분하는 과정이 필요함
- y에 대해 미분하는 식을 나타내면 [그림6]과 같음

$$\begin{aligned}
\frac{\partial y_{hello}}{\partial h_{hello}} &= w_y \\
\frac{\partial y_{hello}}{\partial h_{row}} &= \frac{\partial y_{hello}}{\partial h_{hello}} \times \frac{\partial h_{hello}}{\partial h_{row}} = w_y \times (1 - \tanh^2(h_{row})) \\
\frac{\partial y_{hello}}{\partial h_{say}} &= \frac{\partial y_{hello}}{\partial h_{hello}} \times \frac{\partial h_{hello}}{\partial h_{row}} \times \frac{\partial h_{row}}{\partial h_{say}} = w_y \times (1 - \tanh^2(h_{row})) \times w_h \\
\frac{\partial y_{hello}}{\partial w_x} &= \frac{\partial y_{hello}}{\partial h_{hello}} \times \frac{\partial h_{hello}}{\partial h_{row}} \times \frac{\partial h_{row}}{\partial w_x} = w_y \times (1 - \tanh^2(h_{row})) \times x_{hello} \\
\frac{\partial y_{hello}}{\partial x_{hello}} &= \frac{\partial y_{hello}}{\partial h_{hello}} \times \frac{\partial h_{hello}}{\partial h_{row}} \times \frac{\partial h_{row}}{\partial x_{hello}} = w_y \times (1 - \tanh^2(h_{row})) \times w_x \\
\frac{\partial y_{hello}}{\partial w_h} &= \frac{\partial y_{hello}}{\partial h_{hello}} \times \frac{\partial h_{hello}}{\partial h_{row}} \times \frac{\partial h_{row}}{\partial w_h} = w_y \times (1 - \tanh^2(h_{row})) \times h_{say}
\end{aligned}$$

[그림 6] RNN 역전파 수식

기울기 소실 문제


$$\frac{\partial h_{row}}{\partial w_h} = h_{say} + h_I w_h \odot (1 - h_{say}^2) + h_{and} w_h \odot (1 - h_{say}^2) \odot w_h \odot (1 - h_I^2) + \dots$$

[그림 7] 기울기 전개식

- [그림 7]은 h_{row} 를 w_h 로 미분하는 과정
- Say의 은닉상태인 h_{say} 는 이전 단계의 RNN계층인 you, say, goodbye, and, I의 영향을 받음
- h_{row} 를 w_h 로 미분하려면 h_{you} , h_{say} , $h_{goodbye}$, h_{and} , h_I 를 모두 반영해야 됨
- 가중치, 은닉상태를 계속 곱하고 더하는 패턴이 보이고 이로 인해 **RNN** 계층이 여러 개라면 오차역전파 과정이 꽤 진행되었을 때 업데이트할 기울기가 아주 작은 문제가 발생할 수 있음

RNN의 한계

vanishing gradient problem



[그림 8] 관련 정보와 그 정보를 사용하는 지점 사이 거리가 멀 경우 RNN 학습 능력 저하

- RNN은 관련 정보와 그 정보를 사용하는 지점 사이 거리가 멀 경우 역전파시 기울기가 점차 줄어 학습능력이 크게 저하되는 것으로 알려져 있음
- 이 문제를 극복하기 위해서 고안된 것이 바로 LSTM, GRU가 있음
 - LSTM은 RNN의 은닉상태에 cell-state를 추가한 구조
 - GRU은 LSTM을 개선한 구조