

활성화함수(Activation Function)

[활성화 함수 역할](#)

[활성화 함수의 유형](#)

[계단함수](#)

[시그모이드 함수\(Sigmoid function\)](#)

[ReLU 함수\(Rectified Linear Unit function\)](#)

[Leaky ReLU 함수\(Leaky ReLU function\)](#)

[Softmax 함수\(Softmax function\)](#)

[더 생각해 보기](#)

[왜 비선형적인 활성화 함수만 사용되나?](#)


[기울기 소실](#)

활성화 함수 역할

- 자기가 받은 신호를 잘 살려서 내보내주는 역할
- 아래 두 가지 역할을 함
 - 가중합(가중치*입력값 들의 합, Wx)이 계산되고 나면 값이 너무 크거나 작을 수 있음. 이때 활성화 함수를 통해서 이 값을 0에서 1 또는 -1에서 1 사이의 값 등으로 변환함
 - 활성화 함수 유형에 따라 다름. 전부 다 상하한의 제한이 있는 것은 아님
 - 비선형성을 가진 활성화 함수를 통해서 $Wx+b$ 를 휘게 만들
- 계단함수, 시그모이드, ReLU, ReLU의 변형, 소프트맥스 함수 등이 있음

활성화 함수의 유형


계단함수



$$\begin{cases} 0 & \text{if } x < 0 \\ 1 & \text{if } x \geq 0 \end{cases}$$

- 인공 신경망의 학습 과정 중 역전파(backpropagation)라는 것이 있는데, 이때 활성화 함수의 미분이 필요하다.
- 계단 함수를 미분하니 임계값(0)에서는 미분값이 무한대가 되고 나머지는 0이다. 이는 역전파 과정에서 무의미하므로 계단 함수는 쓰이지 않음

시그모이드 함수(Sigmoid function)




$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

- 로지스틱 회귀에서 사용되는 함수이며 받아들인 값을 0 ~ 1 사이의 값으로 바꿔줌
- 계단 함수는 무의미한 미분 결과를 가진 것에 반해, 시그모이드 함수는 모든 x값에 대하여 미분이 가능함
(즉, 미분값(기울기)이 존재한다)
- 역전파 과정에서 문제점 : 기울기 소실

- 시그모이드 함수를 미분했을 때 미분값은 최대 0.25이다.
 - 2개 층이면 $0.25 \times 0.25 = 0.0625$,
 - 3개 층이면 $0.25 \times 0.25 \times 0.25 = 0.015625 \dots$
- 즉, 시그모이드 함수로 구성된 신경망에서 역전파 과정을 거치면 층이 갈수록 미분값이 작아져서 결국 학습이 제대로 되지 않음
- 이를 기울기 소실이라고 함.
- 기울기 소실로 신경망의 은닉층에서 활성화 함수로 시그모이드를 사용하지 않음
- 이진 분류 문제의 출력층에서 사용됨
 - 예측 결과가 1일 확률을 0~1 사이의 확률값으로 표현

ReLU 함수(Rectified Linear Unit function)




$$\begin{cases} 0 & \text{if } x \leq 0 \\ x & \text{if } x > 0 \end{cases}$$

- 0 이하의 값은 모두 0으로, 그 외에는 들어온 값 그대로 보내주는 방식으로 앞 두 함수와는 달리 역전파에 사용 가능
- 미분을 해도 양수 쪽에서는 기울기가 1이므로 역전파 과정에서 시그모이드 함수처럼 신경망의 층이 갈수록 값이 소실되는 문제 없음
- 신경망의 은닉층에서 주로 사용함
- 문제점 : dying ReLU
 - 양수만 보내주고 음수는 전부 0으로 처리한다. 이로 인해 음수 가중치를 가진 노드들은 썩 다 무시함
- 이 문제점을 해결하기 위해 ReLU 변종들이 나옴
 - Leaky ReLU 함수(Leaky ReLU function)
 - PReLU 함수(Parametric ReLU function)
 - ELU 함수(Exponential Linear Unit) 등

Leaky ReLU 함수(Leaky ReLU function)

- 0 이하의 값에도 아주 약간의 기울기를 부여함



Softmax 함수(Softmax function)

$$\begin{bmatrix} z_1 \\ z_2 \\ z_3 \\ \dots \\ z_k \end{bmatrix} \Rightarrow S(z_i) = \frac{e^{z_i}}{\sum_{j=1}^k e^{z_j}} \Rightarrow \begin{bmatrix} p_1 \\ p_2 \\ p_3 \\ \dots \\ p_k \end{bmatrix}$$

(for $i = 1, \dots, k$)

- 소프트맥스 함수는 선택 가능한 옵션 여러 개를 받아서 각각이 최종 정답일 확률값을 내 보냄
- k개의 원소를 가진 벡터(k차원 벡터)를 입력받은 후 각각에 대한 확률값을 가진 벡터를 출력함
- 확률이므로 출력된 벡터의 원소를 합하면 1이 됨
 - ex) 치킨, 초밥, 김밥 중 오늘의 점심 메뉴는?
 - 각 클래스(입력 - [치킨, 초밥, 김밥])에 대한 확률값(출력)은 0.3, 0.1, 0.6 이면, 모델은 김밥을 결과로 내보냄
- 소프트맥스 함수는 **다중 분류** 문제를 위한 신경망 학습 과정 중 출력층에서 사용

더 생각해 보기

왜 비선형적인 활성화 함수만 사용되나?

- 인공 신경망의 학습 과정에서 가중치-편향 연산만 수행하게 될 경우 각각의 노드의 결과 값은 $Wx+b$ 형태가 됨(W : 가중치 행렬 / x : 입력값 / b : 편향)
- 만약 신경망의 층이 아무리 여러 겹으로 쌓인다 하여도 활성화 함수에서 비선형성을 부여하지 않으면 결국은 직선 형태에서 벗어나질 못함


$$l(x) = ax + b \text{ 라고 하면}$$

$$\begin{aligned} l(l(l(x))) &= l^3(x) \\ &= a(a(ax + b) + b) + b \\ &= a^3x + a^2b + ab + b \end{aligned}$$

$$\begin{aligned} a^3 &= c, a^2b + ab + b = d \text{ 라고 하면} \\ l^3(x) &= cx + d, \text{ 직선이다.} \end{aligned}$$

기울기 소실

인공 신경망 학습 과정 중 역전파에서는 활성화 함수의 미분값을 매 층마다 곱하게 된다. 그런데 이 미분값이 1 미만의 소수인 경우, 여러 번 곱해지다보면 0으로 수렴하여 신경망의 학습이 제대로 이루어질 수가 없음



- 위 그래프는 시그모이드 함수를 미분한 함수의 그래프이다. 보이는 것처럼 최대값이 0.25

- 이 상태로는 층이 많아지면 많아질수록 역전파를 거치면서 기울기 값이 0을 향해 낙하하므로 시그모이드 함수를 은닉층의 활성화 함수로는 사용할 수 없음